



Univerza v Mariboru

Fakulteta za elektrotehniko,
računalništvo in informatiko

Vid Pejovnik

Kulturno prilagodljivi klepetalni roboti

**Pregled področja in smernice za zasnovo kulturno
prilagodljivega sistema z velikimi jezikovnimi modeli**

Individualno raziskovalno delo

Maribor, september 2026

Kulturno prilagodljivi klepetalni roboti

Pregled področja in smernice za zasnovo kulturno prilagodljivega sistema z velikimi jezikovnimi modeli

Individualno raziskovalno delo

Študent(ka):	Vid Pejovnik, mag. inž. el.
Študijski program:	Študijski program 3. stopnje Elektrotehnika
Predmet:	Individualno raziskovalno delo (s seminarjem 1)
Profesor(ica):	dr. Izidor Mlakar

Kazalo vsebine

1	Uvod.....	1
1.1	Raziskovalni problem	2
1.2	Namen in cilji raziskave.....	3
1.3	Raziskovalna vprašanja	3
2	Teoretična izhodišča	5
2.1	Opredelitev kulture.....	5
2.2	Kulturna ozaveščenost, občutljivost in prilagodljivost	7
2.3	Kultura v velikih jezikovnih modelih	10
2.4	Pogovorni sistemi in veliki jezikovni modeli	13
2.4.1	Od osnovnega jezikovnega modela do pogovornega sistema	15
2.4.2	Predhodno učenje in prilagajanje modela.....	15
2.4.3	Generiranje na osnovi LLM v kulturno prilagodljivem sistemu	16
2.4.4	Kontekstno okno in pogovorni spomin.....	16
2.4.5	LLM kot jedro širše modularne arhitekture.....	17
2.5	Mehanizmi kulturnega prilagajanja	18
2.5.1	Pozivno prilagajanje	18
2.5.2	Priklicno podprto generiranje.....	19
2.5.3	Fino nastavljanje in PEFT	20
2.5.4	Aplikacijska in vsebinska plast	22
2.5.5	Persona in interakcijska plast	22
2.5.6	Kulturni profil oz. stanje uporabnika	23
2.5.7	Hibridni pristop	24
2.5.8	Primerjava pristopov.....	25
3	Metodologija raziskave.....	26
3.1	Zasnova pregleda obsega literature	26
3.2	Iskalna strategija in podatkovne baze	27
3.2.1	Zasnova iskalne strategije	27
3.2.2	Omejitve iskanja	27
3.2.3	Rezultati iskanja po podatkovnih bazah	28
3.3	Vključitvena in izključitvena merila.....	28

3.3.1	Vključitvena merila	29
3.3.2	Izključitvena merila	29
3.4	Postopek izbora raziskav.....	29
3.5	Ekstrakcija in kategorizacija podatkov	31
3.5.1	Koncept kulture	31
3.5.2	Sistem in model	32
3.5.3	Cilj kulturne prilagodljivosti	32
3.5.4	Implementacija	32
3.5.5	Viri in orodja.....	32
3.5.6	Vrednotenje in metrike.....	32
3.5.7	Omejitve in raziskovalne vrzeli	33
3.5.8	Eksperimentalna zasnova	33
3.5.9	Človeški udeleženci	33
3.6	Dodatna kategorizacija kulturnega in domenskega prostora znanja	33
3.7	Analiza in sinteza podatkov	34
3.8	Obravnava manjkajočih in nejasno poročanih podatkov	35
4	Rezultati.....	36
4.1	Značilnosti vključenih raziskav	36
4.2	Oprelitev in operacionalizacija kulture.....	37
4.3	Vrste pogovornih sistemov in uporabljeni modeli	38
4.4	Dimenzije kulturne prilagodljivosti.....	39
4.5	Mehanizmi in ravni implementacije kulturne prilagodljivosti.....	41
4.6	Kulturni in domenski prostor znanja	42
4.7	Podatkovne zbirke, primerjalni nabori in ponovno uporabni viri	43
4.8	Načini vrednotenja in uporabljene metrike.....	44
4.9	Eksperimentalne zasnove in udeleženci	46
4.10	Omejitve, tveganja in raziskovalne vrzeli v pregledani literaturi	47
5	Smernice in predlog arhitekture kulturno prilagodljivega pogovornega sistema ..	49
5.1	Izhodišča za zasnovo sistema.....	49
5.2	Zahteve za kulturno prilagodljiv pogovorni sistem	50
5.3	Predlagana arhitektura sistema.....	50
5.3.1	Osnovni večjezični LLM	51

5.3.2	Domenski prostor znanja	52
5.3.3	Kulturni prostor znanja	52
5.3.4	Kulturno stanje uporabnika	54
5.3.5	Analizator poizvedbe	55
5.3.6	Dvojni RAG	55
5.3.7	Krmilnik kulturnega prilagajanja	55
5.3.8	Sestavljalnik poziva	56
5.3.9	Preverjanje generiranega odgovora	57
5.3.10	Povratna informacija in prilagajanje skozi čas	58
5.4	Predlagani kulturni parametri	58
5.5	Predlagano vrednotenje sistema	58
5.5.1	Eksperimentalni pogoji	59
5.5.2	Udeleženci vrednotenja	60
5.6	Predvideni raziskovalni prispevek arhitekture	60
6	Razprava	62
6.1	Kulturna prilagodljivost kot lastnost celotnega sistema	62
6.2	Kultura ni ena sama spremenljivka	62
6.3	Kulturno prilagojen in kulturno prilagodljiv sistem	63
6.4	Vloga RAG, pozivnega prilagajanja in finega nastavljanja	63
6.5	Ločevanje kulturnega in domenskega znanja	64
6.6	Vrednotenje kulturne prilagodljivosti	64
6.7	Človek kot vir kulturnega znanja	65
6.8	Tveganje stereotipizacije in etični vidiki	65
6.9	Raziskovalne vrzeli in nadaljnje delo	66
6.10	Omejitve izvedenega pregleda	66
7	Zaključek	68
	Viri in literatura	70
	Priloge	74
	Priloga A Iskalni nizi posameznih repozitorijev	74
	Priloga B Seznam vključenih raziskav	74

Kazalo slik

Slika 2.1 Arhitektura Transformerja [1]	13
Slika 2.2 Osnovna arhitektura priklicno podprtega generiranja [10]	19
Slika 2.3 Nizkorangirana parametrizacija pri metodi LoRA [12]	21
Slika 3.1 Diagram poteka PRISMA-ScR za identifikacijo, pregled in izbor raziskav, pripravljen skladno s PRISMA-ScR [14]	31
Slika 5.1 Komponente predlagane arhitekture.....	51
Slika 5.2 Predlagana struktura končnega poziva za kulturno prilagodljiv pogovorni sistem	57

Kazalo tabel

Tabela 2.1 Operacionalizacija ključnih pojmov kulturne prilagodljivosti, lastna sinteza na podlagi [5], [7], [9]	9
Tabela 2.2 Primerjava mehanizmov kulturnega prilagajanja	25
Tabela 3.1 Rezultati iskanja po bibliografskih podatkovnih bazah.....	28
Tabela 3.2 Opredelitev elementov PCC v raziskavi.....	28
Tabela 4.1 Porazdelitev vključenih raziskav po letu objave	36
Tabela 4.2 Glavna področja uporabe.....	37
Tabela 4.3 Stopnja formalizacije kulturnega prostora	37
Tabela 4.4 Vrste pogovornih sistemov	38
Tabela 4.5 Najpogostejše navedeni modeli in komponente.....	39
Tabela 4.6 Ciljne dimenzije kulturne prilagodljivosti.....	40
Tabela 4.7 Družine kulturnih parametrov	40
Tabela 4.8 Primarna lokacija kulturne prilagoditve.....	41
Tabela 4.9 Tehnični in razvojni pristopi, uporabljeni pri kulturnem prilagajanju	42
Tabela 4.10 Struktura kulturnega prostora	42
Tabela 4.11 Glavne skupine vrednotenja	44
Tabela 4.12 Najpogostejše družine metrik	45
Tabela 5.1 Predlagani metapodatki kulturnega zapisa.....	53
Tabela 5.2 Primer strukture kulturnega stanja uporabnika	54
Tabela 5.3 Predlagani kulturni parametri	58

Kazalo enačb

Enačba 2.1 Mehanizem skalirane pozornosti s skalarnim produktom [1]	14
Enačba 2.2 Posredovanje skozi plast z nizkorangirano prilagoditvijo LoRA [12].....	21

Seznam uporabljenih kratic

AI – umetna inteligenca (angl. artificial intelligence)

API – vmesnik za programiranje aplikacij (angl. Application Programming Interface)

DOI – digitalni identifikator objekta (angl. Digital Object Identifier)

GAN – generativno kontradiktorno omrežje (angl. Generative Adversarial Network)

GPT – generativni predhodno naučeni transformer (angl. Generative Pre-trained Transformer)

LLM – veliki jezikovni model (angl. large language model)

LoRA – prilagoditev nizkega ranga (angl. Low-Rank Adaptation)

MSM – moški, ki imajo spolne odnose z moškimi (angl. men who have sex with men)

NLP – procesiranje naravnega jezika (angl. natural language processing)

PCC – populacija – koncept – kontekst (angl. Population – Concept – Context)

PEFT – parametrsko učinkovito fino nastavljanje (angl. parameter-efficient fine-tuning)

RAG – priklicno podprto generiranje (angl. Retrieval-Augmented Generation)

SUS – lestvica uporabnosti sistema (angl. System Usability Scale)

WGAN – Wassersteinova generativna kontradiktorna mreža (angl. Wasserstein Generative Adversarial Network)

WVS – svetovna raziskava vrednot (angl. World Values Survey)

Seznam uporabljenih simbolov

Q – matrika poizvedb

K – matrika ključev

V – matrika vrednosti

$(\cdot)^T$ – transponiranje matrike

d_k – dimenzija vektorjev ključev

W_0 – predhodno naučena matrika uteži

ΔW – posodobitev matrike uteži

A, B – učljivi nizkorangirani matriki

$\mathbb{R}$ – množica realnih števil

d – izhodna dimenzija matrike uteži

k – vhodna dimenzija matrike uteži

r – rang prilagoditve

x – vhod v plast

h – izhod oz. skrito stanje plasti

1 Uvod

Veliki jezikovni modeli (angl. large language model, v nadaljevanju LLM) so v zadnjih letih postali ena izmed osrednjih tehnologij na področju procesiranja naravnega jezika (angl. natural language processing, v nadaljevanju NLP). Njihov razvoj temelji predvsem na arhitekturi Transformer, ki z uporabo mehanizma pozornosti omogoča učinkovito modeliranje dolgih zaporedij in odvisnosti med posameznimi deli besedila [1].

Sodobni LLM-ji se praviloma učijo na zelo velikih in raznolikih podatkovnih zbirkah ter jih je mogoče po osnovnem učenju prilagoditi številnim nadaljnjim nalogam. Zaradi takšne splošnosti jih lahko obravnavamo kot temeljne modele (angl. foundation models), ki predstavljajo osnovo za številne aplikacije, med drugim za generiranje besedila, prevajanje, povzemanje, odgovarjanje na vprašanja in pogovorne sisteme [2].

Posebej razširjena uporaba LLM-jev je njihova vključitev v klepetalnike in druge pogovorne sisteme umetne inteligence (angl. conversational AI systems). Tak sistem uporabniku omogoča interakcijo v naravnem jeziku, pri čemer lahko osnovni LLM predstavlja generativno jedro, okoli njega pa so zgrajene dodatne komponente za upravljanje pogovora, priklic zunanega znanja, prilagajanje odzivov in preverjanje izhodov. Uporaba takšnih sistemov ni omejena na eno področje, temveč se pojavlja v zdravstvu, izobraževanju, podpori uporabnikom, duševnem zdravju, jezikovnem učenju in številnih drugih domenah. Široka uporabnost pa hkrati pomeni, da isti sistem uporablja vedno bolj raznolika skupina ljudi, ki se razlikujejo ne samo po jeziku, ampak tudi po kulturnem ozadju, vrednotah, komunikacijskih normah in pričakovanjih [3].

Kultura ima pomembno vlogo pri oblikovanju človekovega vedenja, komunikacije, interpretacije družbenih situacij in prilagajanja različnim okoljem. Kulturno in psihološko prilagajanje se obravnava kot kompleksen proces, na katerega vplivajo značilnosti posameznika, izvirnega in ciljnega kulturnega okolja [4].

Pri raziskovanju medkulturne kompetentnosti pa je treba poudariti, da ta ne predstavlja zgolj poznavanja drugih kultur, temveč vključuje tudi odnos, spretnosti in sposobnost ustreznega delovanja v medkulturnih situacijah [5]. Kulturna inteligenca pa se deli na metakognitivno, kognitivno, motivacijsko in vedenjsko dimenzijo, pri čemer raziskave kažejo, da posamezne dimenzije različno vplivajo na kulturno presojanje, prilagajanje in uspešnost v kulturno raznolikih okoljih [6].

Pri umetni inteligenci (angl. artificial intelligence, v nadaljevanju AI) je vprašanje kulture nekoliko drugačno, saj model kulture ne doživlja na način človeka, temveč jo lahko predstavlja samo prek podatkov, na katerih je bil naučen, dodatnih virov znanja, podanih navodil in informacij o uporabniku oz. kontekstu interakcije [2], [7]. Prav zato se pojavi problem, kaj pri LLM-ju sploh pomeni, da je model »kulturno ozaveščen«, »kulturno občutljiv« ali »kulturno prilagodljiv«. Adilazuarda et al. so v pregledu več kot 90 raziskav o kulturi v LLM ugotovili, da pregledane raziskave kulture praviloma ne definirajo neposredno. Namesto tega uporabljajo različne kulturne približke oz. približne kazalnike

kulture (angl. proxies of culture), kot so nacionalnost, jezik, vrednote, družbene norme in druge demografske ali semantične značilnosti. Avtorji opozarjajo tudi, da so nekateri vidiki kulture raziskani bistveno bolje kot drugi in da še vedno primanjkuje robustnih metod za preverjanje kulturne reprezentacije v praktičnih aplikacijah LLM-jev [7].

LLM-ji niso nujno kulturno nevtralni, saj lahko struktura in sestava učnih podatkov povzročita neenakomerno reprezentacijo različnih jezikov in kulturnih okolij. Tao et al. so pokazali, da so privzeto generirane vrednostne usmeritve modelov družine generativnega predhodno naučenega transformerja (angl. Generative Pre-trained Transformer, v nadaljevanju GPT) bližje nekaterim kulturnim okoljem, kulturno specifično pozivanje pa lahko to usklajenost pri novejših modelih delno izboljša [8].

Poznavanje kulturnih dejstev še ne pomeni nujno sposobnosti kulturnega prilagajanja. Rezultati ogrođa NormAd kažejo, da imajo tudi zmogljivi LLM-ji težave pri uporabi kulturnih norm pri presoji konkretnih družbenih situacij. Kulturna prilagodljivost zato ni odvisna samo od razpoložljivega kulturnega znanja, temveč tudi od njegove pravilne interpretacije in uporabe [9].

1.1 Raziskovalni problem

V literaturi se za opis kulturnih lastnosti pogovornih sistemov uporabljajo različni pojmi, med drugim kulturna ozaveščenost (angl. cultural awareness), kulturna občutljivost (angl. cultural sensitivity), kulturna ustreznost (angl. cultural appropriateness), kulturna usklajenost (angl. cultural alignment) in kulturna prilagodljivost (angl. cultural adaptivity). Ti pojmi niso vedno jasno ločeni, posamezne raziskave pa kulturo operacionalizirajo na različne načine [7].

Dodatna težava je, da kulturna prilagodljivost ne predstavlja enega samega tehničnega problema. Prilagoditev je mogoče izvesti na več ravneh sistema. Kulturna informacija je lahko vključena neposredno v podatke za učenje oz. fino nastavljanje (angl. fine-tuning) modela, podana v pozivu (angl. prompt), pridobljena iz zunanje zbirke znanja, uporabljena pri izbiri vsebine ali pa realizirana na ravni persone, jezika, tona in načina interakcije. Posledično kulturno prilagodljiv sistem ni nujno posebna arhitektura LLM-ja, ampak je lahko kombinacija osnovnega modela in več dodatnih komponent [7], [10], [11], [12].

Podobno heterogeno je tudi vrednotenje. Kulturna ustreznost se lahko ocenjuje neposredno z ocenami kulturne občutljivosti in primernosti, posredno pa tudi z uporabnostjo, sprejemljivostjo, zaupanjem, vključenostjo uporabnikov in tehničnimi merami pravilnosti. Zaradi različnih domen, ciljnih skupin, modelov, eksperimentalnih zasnov in uporabljenih metrik je rezultate posameznih raziskav težko neposredno primerjati. Osrednji raziskovalni problem tega dela je zato ugotoviti, kako je kulturna prilagodljivost pogovornih sistemov trenutno konceptualizirana, implementirana in vrednotena ter katere ugotovitve obstoječih raziskav so uporabne pri zasnovi prihodnjega kulturno prilagodljivega pogovornega sistema z LLM-ji.

1.2 Namen in cilji raziskave

Namen dela je sistematično pregledati sodobne raziskave na področju kulturno prilagodljivih klepetalnikov in pogovornih sistemov ter ugotoviti, kako raziskovalci definirajo kulturo, katere kulturne značilnosti vključujejo v sisteme ter na kakšen način kulturno prilagodljivost tehnično implementirajo in vrednotijo.

Ker je področje terminološko in metodološko heterogeno, je raziskava zasnovana kot pregled obsega literature (angl. scoping review). Tak pristop je primeren predvsem za kartiranje širšega in raznolikega raziskovalnega področja, prepoznavanje glavnih konceptov, uporabljenih metod in raziskovalnih vrzeli [13]. Potek pregleda in poročanje sta zasnovana skladno s smernicami PRISMA-ScR [14].

Glavni cilji raziskave so:

- ugotoviti, kako je kultura definirana in operacionalizirana v raziskavah kulturno prilagodljivih pogovornih sistemov,
- identificirati uporabljene modele, arhitekture in vrste klepetalnikov,
- določiti, katere dimenzije kulture so vključene v prilagajanje,
- pregledati tehnične mehanizme kulturnega prilagajanja, kot so prilagajanje s pozivi, priklic zunanega znanja, fino nastavljanje in prilagoditve na aplikacijski oz. interakcijski ravni,
- ugotoviti, katere podatkovne zbirke, kulturni in domenski viri znanja, primerjalni nabori ter orodja se uporabljajo,
- analizirati načine vrednotenja in uporabljene metrike,
- pregledati eksperimentalne zasnove in značilnosti udeležencev,
- identificirati glavne omejitve, tveganja in odprta raziskovalna vprašanja,
- na podlagi sinteze rezultatov določiti smernice za nadaljnji razvoj kulturno prilagodljivega pogovornega sistema z LLM-ji.

1.3 Raziskovalna vprašanja

RV1: Kako je kultura definirana in operacionalizirana v raziskavah kulturno prilagodljivih klepetalnikov in pogovornih sistemov umetne inteligence?

RV2: Katere vrste pogovornih sistemov, arhitektur klepetalnikov in družin modelov se uporabljajo pri raziskovanju kulturno prilagodljivih klepetalnikov?

RV3: Katere dimenzije kulturne prilagodljivosti so predmet prilagajanja?

RV4: Kateri tehnični mehanizmi se uporabljajo za implementacijo kulturne prilagodljivosti v klepetalnikih in pogovornih sistemih?

RV5: Kateri podatkovni viri, podatkovne zbirke, primerjalni nabori, orodja in ponovno uporabna ogrodja podpirajo razvoj kulturno prilagodljivih klepetalnikov?

RV6: Kako se kulturna prilagodljivost klepetalnikov vrednoti?

RV7: Katere metrike se uporabljajo za vrednotenje kulturne prilagodljivosti in kaj posamezna metrika meri?

RV8: Katere omejitve, tveganja in raziskovalne vrzeli navaja literatura o kulturno prilagodljivih klepetalnikih?

RV9: Katere vrste eksperimentov in raziskovalnih zasnov se uporabljajo pri razvoju in vrednotenju kulturno prilagodljivih klepetalnikov ter katere vidike kulturne prilagodljivosti preverjajo?

RV10: Kdo so človeški udeleženci pri razvoju in vrednotenju kulturno prilagodljivih klepetalnikov, kako veliki so vzorci in kako so udeleženci opisani?

2 Teoretična izhodišča

2.1 Opredelitev kulture

Kultura je kompleksen in večplasten pojem, ki ga različna raziskovalna področja opredeljujejo na različne načine. V splošnem ne predstavlja samo jezika, narodnosti ali geografskega okolja, ampak širši sistem vrednot, norm, vedenjskih vzorcev, prepričanj in načinov komunikacije, ki se oblikujejo in prenašajo znotraj družbenih skupin. Posameznik je lahko hkrati del več kulturnih okolij, zato kulture ni smiselno razumeti kot enotne in nespremenljive lastnosti posameznika. Kulturno vedenje je lahko odvisno od države, jezika, etnične ali verske skupnosti, generacije, družbenega okolja in konkretne situacije, v kateri poteka interakcija [4], [7].

Eden izmed vplivnejših pristopov k primerjavi kultur temelji na kulturnih dimenzijah. Hofstede je na podlagi mednarodnih podatkov razvil model, v katerem je mogoče kulture primerjati glede na več značilnosti, med drugim glede na distanco moči, izogibanje negotovosti, individualizem oz. kolektivizem, maskulinitet oz. femininitet ter dolgoročno oz. kratkoročno usmerjenost. Takšne dimenzije omogočajo sistematično primerjavo kulturnih okolij, zato se pogosto uporabljajo tudi v raziskavah komunikacije, organizacijskega vedenja in medkulturnih razlik. Hofstedejev model je zasnovan predvsem za primerjavo kultur na ravni držav oz. večjih družbenih skupin, ne pa za neposredno napovedovanje vedenja posameznika [15].

Prav ta razlika med skupinsko in individualno ravno predstavlja pomembno omejitev pri uporabi kulturnih dimenzij v prilagodljivih sistemih. Nacionalne kulturne ocene predstavljajo povprečne značilnosti skupine, zato iz njih ni mogoče neposredno sklepati, da bo imel vsak posameznik iz določene države enake vrednote ali komunikacijske preference. Takšna uporaba lahko vodi v t. i. ekološko zmoto (angl. ecological fallacy), pri kateri se lastnosti, ugotovljene na ravni skupine, napačno prenesejo na posameznika. To je posebej pomembno pri kulturno prilagodljivih klepetalnikih, saj bi sistem, ki uporabnika prilagaja samo na podlagi njegove države ali narodnosti, lahko ustvarjal stereotipne in napačne predpostavke [16].

Drugačen pristop k kulturnim razlikam predstavlja Schwartzova teorija vrednot. Schwartz je na podlagi raziskav v različnih državah identificiral več skupin vrednot in pokazal, da je mogoče kulturna okolja primerjati glede na strukturo njihovih vrednostnih prioritet. Njegovo zgodnejše delo opredeljuje deset motivacijsko različnih tipov vrednot, ki se pojavljajo v različnih kulturnih okoljih [17]. Kasneje je razvil tudi teorijo sedmih kulturnih vrednostnih usmeritev, organiziranih v tri širše dimenzije. Takšni modeli so pomembni, ker kulturo obravnavajo predvsem skozi vrednote in njihove medsebojne odnose, ne samo skozi nacionalno pripadnost [18].

Za vprašanje kulturne prilagodljivosti je pomemben tudi Berryjev model akulturacije in prilagajanja. Berry kulturno prilagajanje obravnava kot proces, ki nastane ob stiku posameznika z drugačnim kulturnim okoljem in je odvisen tako od značilnosti

posameznika kot od značilnosti izvirnega ter ciljnega okolja. Pomembna ugotovitev tega pristopa je, da kulturna prilagoditev ni enosmeren proces, pri katerem bi posameznik samo prevzel lastnosti druge kulture, temveč je rezultat interakcije več osebnih in družbenih dejavnikov [4].

Za razvoj kulturno prilagodljive AI so navedeni modeli uporabni predvsem kot teoretično izhodišče za določanje možnih kulturnih značilnosti. Vendar noben izmed njih sam po sebi ne predstavlja popolnega modela kulture, ki bi ga bilo mogoče neposredno vključiti v pogovorni sistem. Hofstedejeve dimenzije npr. omogočajo primerjavo kulturnih okolij, vendar so zasnovane na agregirani ravni in zato niso neposredno primerne za individualno prilagajanje. Schwartzovi modeli bolje opisujejo vrednostne usmeritve, vendar kultura tudi v tem primeru ni omejena samo na vrednote. Berry pa poudarja dinamičnost kulturnega prilagajanja, kar je posebej zanimivo pri pogovornih sistemih, ki bi se lahko uporabniku prilagajali skozi več zaporednih interakcij [4], [15], [17], [18].

V kontekstu LLM-jev je zato smiselno kulturo razumeti kot večdimenzionalen in kontekstno odvisen prostor, ki lahko vključuje tako relativno stabilne podatke, kot so jezik, regionalno okolje ali pripadnost določeni skupnosti, kot tudi bolj dinamične značilnosti, kot so način komunikacije, stopnja formalnosti, občutljivost posamezne teme, preference uporabnika in odzivi v trenutnem pogovoru. Takšno razumevanje je skladno tudi z novejšimi raziskavami kulture v LLM, ki opozarjajo, da kultura ni neposredno opredeljena z eno samo spremenljivko. Adilazuarda et al. so pri pregledu več kot 90 raziskav ugotovili, da avtorji praviloma uporabljajo različne kulturne približke, ki jih razvrstijo v demografske in semantične kategorije [7].

Demografski kulturni približki lahko vključujejo npr. državo, nacionalnost, jezik, etnično pripadnost ali geografsko območje, medtem ko semantični približki predstavljajo vsebinske vidike kulture, kot so vrednote, norme, običaji, vedenje in kulturno specifično znanje. Takšna razdelitev je pomembna za kulturno prilagodljive klepetalnike, saj kaže, da ni dovolj poznati samo demografske oznake uporabnika. Za dejansko prilagajanje je treba upoštevati tudi vsebinski oz. semantični del kulture ter način, kako se ta izraža v konkretni komunikacijski situaciji [7].

Za potrebe tega raziskovalnega dela bo zato kultura obravnavana širše kot nacionalna ali jezikovna pripadnost. Kulturni kontekst lahko vključuje demografske značilnosti, jezik in register, vrednote, komunikacijske norme, pričakovano stopnjo formalnosti, občutljivost posameznih tem, družbene norme, lokalne primere in druge dejavnike, ki vplivajo na način, kako uporabnik razume in sprejema odziv pogovornega sistema. Takšna širša opredelitev je pomembna tudi pri poznejši analizi pregledanih raziskav, saj omogoča ugotavljanje, katere dele tega kulturnega prostora posamezni sistemi dejansko uporabljajo in kako formalno jih predstavljajo.

2.2 Kulturna ozaveščenost, občutljivost in prilagodljivost

Pri raziskovanju kulturno prilagodljivih sistemov je pomembno razlikovati med več sorodnimi pojmi, ki se v literaturi pogosto uporabljajo nekoliko nedosledno. Med najpogostejšimi so kulturna ozaveščenost, kulturno znanje (angl. cultural knowledge), kulturna občutljivost, kulturna ustreznost, medkulturna kompetentnost (angl. intercultural competence) in kulturna prilagodljivost [5], [7], [9]. Ker med temi pojmi ni enotne terminološke hierarhije, jih za potrebe tega raziskovalnega dela operacionaliziramo glede na to, ali sistem kulturo zgolj prepozna, jo zna opisati, jo upošteva pri oblikovanju odziva ali pa svoje vedenje dejansko spreminja glede na kulturni kontekst.

Kulturna ozaveščenost predstavlja osnovno sposobnost prepoznavanja, da med posamezniki in skupinami obstajajo kulturne razlike. V kontekstu pogovornega sistema bi lahko to pomenilo, da sistem prepozna, da uporabniki iz različnih jezikovnih ali kulturnih okolij ne uporabljajo nujno enakega komunikacijskega sloga in da imajo lahko različna pričakovanja glede odzivov. Sama kulturna ozaveščenost še ne pomeni, da sistem zaradi tega spremeni svoje vedenje.

Naslednjo raven predstavlja kulturno znanje. Sistem ima lahko informacije o kulturnih normah, vrednotah, običajih, komunikacijskih vzorcih ali lokalnem okolju. Takšno znanje je lahko prisotno že v parametrih osnovnega modela zaradi predhodnega učenja ali pa je sistemu dodano prek zunanjih podatkovnih zbirk, baz znanja oz. priklica informacij. Tudi v tem primeru pa samo razpoložljivost informacij še ne zagotavlja, da jih bo model v konkretni situaciji pravilno uporabil [9].

Ta problem je posebej dobro viden pri vrednotenju kulturnih sposobnosti LLM-jev. Pri ogrožju NormAd razlikujejo med poznavanjem norm in sposobnostjo njihove uporabe v konkretnih kulturnih situacijah. Rezultati kažejo, da lahko model pozna relevantno kulturno informacijo, vendar to še ne pomeni, da jo bo pravilno vključil v presojo ali odziv. Zato kulturnega znanja in kulturne prilagodljivosti ni smiselno obravnavati kot iste lastnosti [9].

Kulturna občutljivost predstavlja korak naprej, saj pomeni, da sistem kulturne razlike upošteva tako, da se izogne neprimernim, žaljivim ali kulturno neustreznim odzivom. Pri klepetalniku se lahko kulturna občutljivost kaže v izbiri jezika, načinu naslavljanja uporabnika, stopnji formalnosti, izbiri primerov, obravnavi občutljivih tem in izogibanju stereotipom. Kulturna občutljivost je zato predvsem vprašanje kakovosti in primernosti odziva glede na kulturni kontekst. S kulturno občutljivostjo je tesno povezana kulturna ustreznost. Ta se nanaša na vprašanje, ali je posamezen odziv, primer, priporočilo ali način komunikacije primeren za določeno kulturno okolje. V raziskavah se ta lastnost pogosto meri z ocenami uporabnikov ali strokovnjakov, ki presojajo kulturno primernost, spoštljivost, relevantnost ali občutljivost odziva [5], [7].

Širši pojem predstavlja medkulturna kompetentnost. Deardorff jo obravnava kot sposobnost učinkovitega in primerne delovanja v medkulturnih situacijah, pri čemer niso pomembni samo znanje, ampak tudi odnos, spretnosti in vedenjski rezultati. Pomembno je tudi, da Deardorff pri vrednotenju medkulturne kompetentnosti ne predlaga ene same meritve, temveč kombiniranje kvantitativnih in kvalitativnih metod, npr. samoocen, opazovanja, intervjujev in ocen drugih oseb. Takšen pogled je uporaben tudi za kulturno prilagodljive AI-sisteme, saj njihove kulturne ustreznosti verjetno ni mogoče zanesljivo oceniti samo z eno avtomatsko metriko [5].

Soroden koncept je kulturna inteligenca (angl. cultural intelligence), ki jo opredeljujejo kot sposobnost učinkovitega delovanja v kulturno raznolikih okoljih. Model razlikuje štiri komponente: metakognitivno, kognitivno, motivacijsko in vedenjsko kulturno inteligenco. Kognitivna komponenta predstavlja poznavanje kultur, metakognitivna sposobnost refleksije in prilagajanja kulturnih predpostavk, motivacijska pripravljenost za delovanje v medkulturnem okolju, vedenjska pa dejansko spremembo vedenja. Avtorji so pokazali, da so različne dimenzije povezane z različnimi rezultati, kot so kulturna presoja, prilagajanje in uspešnost naloge. Takšna razdelitev je zanimiva tudi za AI. Če jo prenesemo na pogovorni sistem, bi lahko kulturno znanje približno primerjali s kognitivno komponento, sposobnost izbire ustrezne kulturne strategije z metakognitivno komponento, dejansko spremembo jezika, tona ali vsebine pa z vedenjsko komponento. Motivacijska komponenta pri AI nima neposrednega človeškega ekvivalenta, vendar bi jo lahko funkcionalno nadomestil mehanizem oz. krmilnik, ki določa, kdaj in v kolikšni meri naj se prilagoditev izvede. Takšna preslikava ni neposredno povzeta iz modela Ang et al., temveč predstavlja konceptualno interpretacijo za potrebe zasnove AI-sistema [6].

V operacionalizaciji, uporabljeni v tem delu, kulturna prilagodljivost predstavlja raven, pri kateri sistem kulturnega konteksta ne samo zazna ali pozna, temveč na njegovi podlagi spreminja svoje vedenje oz. generirani odziv. Prilagoditev se lahko izvede na različne načine: z izbiro drugačnega jezika ali registra, prilagoditvijo tona, spremembo primerov in razlage, uporabo kulturno specifičnega znanja, izbiro druge vsebine, spreminjanjem persone ali z dodatnimi navodili osnovnemu jezikovnemu modelu.

Pomembna je tudi razlika med kulturno prilagojenim in kulturno prilagodljivim sistemom. Kulturno prilagojen sistem je lahko vnaprej zasnovan za eno določeno skupino, npr. zdravstveni klepetalnik, katerega vsebina in jezik sta bila med razvojem prilagojena določeni skupnosti. Tak sistem se med uporabo ni nujno sposoben dodatno prilagajati. Kulturno prilagodljiv sistem pa bi moral kulturni kontekst uporabljati kot vhodno informacijo in na njegovi podlagi dinamično spreminjati svoje odzive. Ta razlika bo posebej pomembna pri analizi pregledanih raziskav, saj omogoča razlikovanje med vnaprej kulturno prilagojenimi sistemi in sistemi, ki kulturni kontekst dinamično uporabljajo med interakcijo.

Za potrebe tega dela lahko zato pojme približno uredimo v naslednje zaporedje:

kulturna ozaveščenost → kulturno znanje → kulturna občutljivost oz. ustreznost → kulturna prilagoditev → kulturna prilagodljivost

Pri tem zadnja stopnja pomeni, da kulturne informacije dejansko sodelujejo pri odločanju sistema in se lahko odziv spremeni glede na uporabnika, situacijo ali potek pogovora. Takšno razlikovanje bo uporabljeno tudi v nadaljevanju dela pri razvrščanju obstoječih rešitev in pri oblikovanju predloga arhitekture kulturno prilagodljivega klepetalnika. Na podlagi predstavljenih konceptov lahko ključne pojme, uporabljene v nadaljevanju raziskave, povzamemo z operacionalizacijo v tabeli 2.1.

Tabela 2.1 Operacionalizacija ključnih pojmov kulturne prilagodljivosti, lastna sinteza na podlagi [5], [7], [9]

Pojem	Osnovna značilnost	Primer v pogovornem sistemu
Kulturna ozaveščenost	Sistem prepozna obstoj kulturnih razlik	Prepozna, da se lahko pričakovani komunikacijski slog med uporabniki razlikuje
Kulturno znanje	Sistem ima dostop do informacij o normah, vrednotah, običajih ali kulturnem okolju	Pozna lokalno družbeno normo ali kulturno specifično informacijo
Kulturna občutljivost	Sistem pri odzivu upošteva kulturne razlike in zmanjšuje nevarnost neustreznih ali stereotipnih odzivov	Izogiba se neprimernemu načinu naslavljanja ali kulturno neustreznim primerom
Kulturna ustreznost	Posamezni odziv je primeren za konkreten kulturni kontekst	Izbere primeren ton, register, primer ali način razlage
Kulturna prilagoditev	Sistem je prilagojen določeni kulturi oz. skupini	Vnaprej lokaliziran klepetalnik za določeno skupnost
Kulturna prilagodljivost	Sistem kulturni kontekst uporablja dinamično in na njegovi podlagi spreminja odziv	Med pogovorom spremeni slog ali vsebino glede na uporabnikove izražene preference

2.3 Kultura v velikih jezikovnih modelih

LLM-ji kulturnega znanja ne vsebujejo v obliki ene jasno določene zbirke pravil ali ločenega kulturnega modula. Njihovo osnovno vedenje nastane med učenjem na zelo velikih količinah besedila, iz katerih model med učenjem oblikuje statistične predstavitve povezav med besedami, pojmi, dogodki, vrednotami in načini izražanja. Posledično se v naučenih predstavitev poleg jezikovnih in splošnih semantičnih informacij pojavijo tudi kulturni vzorci, ki so prisotni v učnih podatkih. Kateri kulturni vzorci bodo v modelu bolje zastopani, je zato med drugim odvisno od jezika, izvora, količine in sestave podatkov, uporabljenih pri njegovem učenju. Ker so veliki spletni korpusi neenakomerno porazdeljeni med jeziki in geografskimi območji, kulturna reprezentacija v LLM ni nujno uravnotežena [2], [7].

Prav problem opredelitve kulture v LLM sistematično obravnavajo Adilazuarda et al. V pregledu več kot 90 raziskav so ugotovili, da nobena izmed analiziranih raziskav kulture ni jasno in celovito definirala, temveč so avtorji posamezne vidike kulture predstavljali prek različnih kulturnih približkov. Te kulturne približke avtorji razvrstijo predvsem na demografske in semantične. Demografski približki predstavljajo npr. jezik, državo ali drugo skupinsko pripadnost, semantični pa vsebinske značilnosti kulture, kot so vrednote, norme in kulturno specifično znanje. Pregled je pokazal tudi, da so določeni vidiki kulture, zlasti vrednote in cilji, bistveno pogostejše raziskani kot drugi kulturni pojavi [7].

Takšna ugotovitev je pomembna pri razumevanju kulturno prilagodljive AI, saj kaže, da »kultura modela« ni ena sama lastnost, ki bi jo lahko izmerili z eno vrednostjo. Model je lahko npr. dober pri poznavanju kulturno značilnih jedi ali praznikov, hkrati pa lahko slabo razume družbene norme, komunikacijske preference ali primernost vedenja v določeni situaciji. Podobno lahko pravilno odgovori na vprašanje o kulturnem običaju, vendar tega znanja ne uporabi pravilno pri pogovoru z uporabnikom. Zato je pri LLM smiselno ločiti najmanj med kulturnim znanjem, kulturno reprezentacijo, kulturno usklajenostjo in kulturno prilagodljivostjo.

Kulturno znanje predstavlja informacije, ki jih model lahko prikliče oz. generira o določeni kulturi. Sem lahko sodijo podatki o jeziku, običajih, vrednotah, zgodovinskih dogodkih, družbenih pravilih, praznikih ali vsakodnevnih praksah. Kulturna reprezentacija je širši pojem in se nanaša na to, kako so različni kulturni pogledi in vzorci zastopani v vedenju modela. Kulturna usklajenost pa opisuje, v kolikšni meri so odgovori modela skladni z vrednotami, normami oz. pričakovani določene kulturne skupine. Kulturna prilagodljivost je še zahtevnejša lastnost, saj predpostavlja, da sistem kulturni kontekst uporabi pri spreminjanju svojega odziva.

Da LLM-ji niso nujno kulturno nevtralni, kaže raziskava Tao et al., ki so analizirali pet različic modelov družine GPT in njihove odgovore primerjali z nacionalno reprezentativnimi podatki svetovne raziskave vrednot (angl. World Values Survey, v nadaljevanju WVS) in European Values Study. Avtorji so ugotovili, da so neodvisno od

izbrane različice modela privzeto generirane vrednote bližje vrednotam angleško govorečih in protestantskih evropskih držav. Takšen rezultat kaže, da lahko model pri odsotnosti dodatnega kulturnega konteksta generira odzive, ki niso kulturno nevtralni, ampak so bližje določenim kulturnim okoljem [8].

Pomemben del iste raziskave je bilo preverjanje, ali je mogoče kulturno usklajenost izboljšati brez spremembe osnovnega modela. Avtorji so uporabili kulturno specifično pozivanje (angl. cultural prompting), pri katerem so modelu v pozivu določili ustrezno kulturno identiteto oz. kontekst. Pri novejših modelih GPT-4, GPT-4-turbo in GPT-4o se je s takšnim pristopom kulturna usklajenost izboljšala pri približno 71 do 81 % analiziranih držav in območij. Rezultat je pomemben, ker pokaže, da je mogoče vsaj del kulturnega vedenja modela nadzorovati na ravni poziva. Hkrati pa takšna prilagoditev ni delovala v vseh primerih. Pri nekaterih državah in območjih kulturno pozivanje ni izboljšalo usklajenosti oz. jo je celo poslabšalo. Zato samo dodajanje države ali kulture v poziv še ne predstavlja zanesljive rešitve za kulturno prilagajanje [8].

Še pomembnejša je razlika med poznavanjem kulture in sposobnostjo uporabe kulturnega znanja. V ogrodju NormAd se kulturna prilagodljivost vrednoti prek sposobnosti modela, da presoja družbeno sprejemljivost situacij pri različnih stopnjah razpoložljivega kulturnega konteksta. Za vrednotenje so oblikovali zbirko NormAd-Eti, ki vsebuje približno 2.600 situacij, povezanih z družbenim bontonom in normami iz 75 držav [9].

V raziskavi so modelom kulturni kontekst podajali z različnimi stopnjami specifičnosti, od bolj abstraktnih vrednot in informacije o državi do eksplicitno navedene družbene norme. Tudi ko je bila modelu relevantna norma neposredno podana, so najboljši modeli dosegli manj kot 82 % pravih presoj, človeški udeleženci pa so dosegli več kot 95-odstotno uspešnost. Pri bolj abstraktnih kulturnih informacijah, kot sta vrednota in država, je uspešnost modelov padla pod 60 %, človeški udeleženci pa so ohranili več kot 90-odstotno natančnost. Ti rezultati kažejo, da problem kulturne prilagodljivosti ni samo v tem, ali je kulturna informacija modelu dostopna, ampak tudi v tem, ali jo zna pravilno interpretirati in uporabiti pri odločanju [9].

Poleg raziskav posameznih kulturnih norm obstajajo tudi primerjalni nabori, ki skušajo kulturne lastnosti LLM oceniti bolj strukturirano. Primer je CDEval, ki je bil razvit kot primerjalni nabor za vrednotenje kulturnih dimenzij LLM-jev. Nabor obravnava šest kulturnih dimenzij v sedmih domenah in je bil sestavljen s kombinacijo avtomatskega generiranja z GPT-4 in človeškega preverjanja. Avtorji so pri primerjavi več glavnih LLM ugotovili razlike tako med posameznimi kulturnimi dimenzijami kot med različnimi domenami, kar dodatno kaže, da kulturnega vedenja modela ni mogoče smiselno oceniti samo z eno splošno metriko [19].

Kulturna prilagoditev se lahko izvede tudi globlje kot samo na ravni poziva. Primer takšnega pristopa predstavlja CultureLLM. Avtorji izhajajo iz problema pomanjkanja kakovostnih učnih podatkov za kulture in jezike z manj viri. Kot začetni kulturni vir

uporabijo podatke World Values Survey, nato pa z metodo semantične razširitve podatkov (angl. semantic data augmentation) ustvarijo dodatne učne primere. Na tej osnovi fino nastavijo kulturno specifične modele za devet kultur in tudi en skupen model CultureLLM-One [20].

Posebej zanimivo je, da so v CultureLLM za posamezne kulture začeli s samo 50 izvornimi primeri iz WVS in jih nato razširili s semantično razširitvijo podatkov. Modeli so bili ovrednoteni na 60 kulturno povezanih podatkovnih zbirkah. Avtorji poročajo, da je CultureLLM v njihovem eksperimentalnem okviru presegel GPT-3.5 za 8,1 % in Gemini Pro za 9,5 %, dosežena uspešnost pa je bila primerljiva z GPT-4 oz. v nekaterih nalogah tudi boljša. Ta pristop kaže, da je mogoče na kulturno vedenje modela vplivati tudi z namenskim učnim procesom in ne samo s pozivi, vendar takšno prilagajanje zahteva pripravo ustreznih kulturnih učnih podatkov [20].

Primeri kulturnega pozivanja, CultureLLM in NormAd tako predstavljajo tri različne vidike istega problema. Kulturno pozivanje spreminja kontekst generiranja, CultureLLM spreminja model oz. njegove parametre, NormAd pa preverja, ali model kulturno informacijo dejansko uporabi pri presoji. Pri razvoju kulturno prilagodljivega klepetalnika je pomembno ločevati te ravni, saj visoka uspešnost na eni izmed njih ne zagotavlja uspešnosti na drugih.

Pomemben problem je tudi nevarnost prekomernega posploševanja. Če je modelu kot edina kulturna informacija podana država uporabnika, lahko sistem implicitno predpostavi, da ima uporabnik lastnosti povprečnega predstavnika te države. Takšen pristop lahko poveča stereotipizacijo namesto kulturne občutljivosti. Podobno lahko jezik predstavlja uporaben signal kulturnega konteksta, vendar iz izbire jezika ni mogoče neposredno sklepati na vse vrednote ali preference uporabnika. Pri kulturno prilagodljivem sistemu je zato smiselno kulturne demografske podatke obravnavati kot kontekst oz. začetni signal, ne pa kot dokončen opis uporabnika.


Iz navedenih ugotovitev izhaja, da je pri obravnavi kulturnega konteksta smiselno upoštevati več vrst informacij, npr. jezik in lokalno okolje, komunikacijski slog, kulturne norme, vrednote, občutljivost posameznih tem in uporabniške preference. Pomembna je tudi možnost, da se začetna kulturna predstavitev med pogovorom dopolni ali spremeni glede na neposredno izražene preference uporabnika.

Za potrebe tega raziskovalnega dela je zato mogoče kulturo v LLM obravnavati na treh osnovnih ravneh. Prva predstavlja kulturno znanje, torej informacije, ki jih model že vsebuje oz. jih je mogoče pridobiti iz zunanjega vira. Druga predstavlja kulturno usklajevanje, pri katerem se vedenje modela usmerja proti določenemu kulturnemu kontekstu, npr. s pozivi ali finim nastavljanjem. Tretja pa predstavlja kulturno prilagodljivost, pri kateri sistem kulturne informacije dinamično izbira in uporablja glede na uporabnika, domeno ter trenutno pogovorno situacijo. Prav zadnja raven je osrednji cilj kulturno prilagodljivega pogovornega sistema, obravnavanega v tem delu.

2.4 Pogovorni sistemi in veliki jezikovni modeli

Pogovorni sistemi umetne inteligence so sistemi, katerih osnovni namen je omogočiti interakcijo med človekom in računalnikom z uporabo naravnega jezika. Mednje sodijo besedilni klepetalniki, virtualni pomočniki, glasovni pomočniki in druge oblike pogovornih agentov. Starejši pogovorni sistemi so pogosto temeljili na vnaprej pripravljenih pravilih, drevesih dialoga, predlogah odgovorov ali kombinaciji klasifikacije uporabnikovega namena in vnaprej določenih odzivov. Takšni sistemi imajo prednost velike nadzorovanosti, vendar je njihovo delovanje omejeno na scenarije, ki jih je razvijalec predvidel pri zasnovi sistema. Razvoj globokega učenja in predvsem LLM-jev je omogočil prehod proti generativnim pogovornim sistemom, pri katerih odziv ni nujno vnaprej pripravljen, temveč ga model ustvari glede na trenutno uporabnikovo sporočilo in kontekst pogovora [3].

Osnova večine sodobnih LLM-jev je arhitektura Transformer. Transformer uporablja mehanizem samopozornosti (angl. self-attention), pri katerem se predstavitev posameznega elementa zaporedja izračuna ob upoštevanju drugih elementov v istem zaporedju. Takšen način obdelave omogoča modeliranje povezav med deli besedila, ki so lahko med seboj precej oddaljeni, hkrati pa omogoča bistveno večjo stopnjo paralelizacije obdelave kot rekurentne arhitekture [1].



Slika 2.1 Arhitektura Transformerja [1]

Slika 2.1 prikazuje izvirno kodirniško-dekodirniško arhitekturo Transformerja, katere osrednji gradnik je mehanizem večglave pozornosti. Jedro mehanizma pozornosti predstavlja skalirana pozornost s skalarnim produktom (angl. scaled dot-product attention), pri kateri se podobnost med poizvedbami in ključi izračuna s skaliranim skalarnim produktom, uteži pa se nato uporabijo za kombiniranje vrednosti [1].

Enačba 2.1 Mehanizem skalirane pozornosti s skalarnim produktom [1]

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V$$

Pri tem Q , K in V predstavljajo matrice poizvedb (angl. queries), ključev (angl. keys) in vrednosti (angl. values), d_k pa dimenzijo vektorjev ključev. Skaliranje z $\sqrt{d_k}$ preprečuje, da bi pri večjih dimenzijah ključev skalarni produkti dosegali velike vrednosti, zaradi katerih bi funkcija softmax prešla v območja z zelo majhnimi gradienti [1].

Besedilo se pred obdelavo v LLM-ju praviloma razdeli na manjše enote oz. žetone (angl. tokens). Žeton lahko predstavlja celo besedo, del besede, ločilo ali drug del besedilnega zapisa. Model posamezne žetone pretvori v numerične predstavitve oz. vektorske vložitve (angl. embeddings), nato pa jih skozi zaporedje plasti Transformerja obdeluje v kontekstu drugih žetonov. Ker sam mehanizem pozornosti ne vsebuje informacije o vrstnem redu elementov, mora model dodatno vključiti informacijo o njihovem položaju v zaporedju [1].

Pri generativnih LLM-jih je rezultat obdelave vhodnega konteksta porazdelitev verjetnosti za naslednji možni žeton. Model torej pri generiranju ne pripravi celotnega odgovora naenkrat, ampak zaporedno napoveduje naslednje žetone. Ko je izbran naslednji žeton, se ta doda obstoječemu zaporedju in postopek se ponovi. Takšen način generiranja se imenuje avtoregresivno generiranje. Če uporabnik npr. vpraša »Kako lahko zmanjšam stres pred izpitom?«, model na podlagi vprašanja, sistemskih navodil in morebitnega predhodnega pogovora postopoma ustvarja nadaljevanje, ki tvori končni odgovor [21].

Prav takšno generiranje je pomembno tudi pri kulturni prilagodljivosti. Osnovna generativna sposobnost modela se namreč ne spremeni, lahko pa se spremeni kontekst, na podlagi katerega model napoveduje naslednji žeton. Če je modelu poleg vprašanja podana informacija o jeziku, želenem komunikacijskem slogu, kulturno občutljivih temah ali kulturno relevantnih primerih, lahko te informacije vplivajo na verjetnosti različnih možnih nadaljevanj. Kulturna prilagoditev zato ni nujno izvedena z novo arhitekturo generativnega modela, temveč se lahko izvede tudi s spreminjanjem informacij, ki so modelu na voljo v času generiranja.

2.4.1 Od osnovnega jezikovnega modela do pogovornega sistema

Pomembno je razlikovati med LLM-jem kot modelom in pogovornim sistemom, ki uporablja LLM. LLM je predvsem komponenta, ki na osnovi vhodnega konteksta generira oz. ocenjuje jezikovne izhode. Klepetalnik pa je širši programski sistem, ki lahko poleg LLM vključuje upravljanje uporabniške seje, zgodovino pogovora, systemske pozive, podatkovne zbirke, zunanja orodja, mehanizme za priklic informacij, uporabniški profil, varnostne mehanizme in druge komponente [2], [3]. Sodobne velike modele je zato smiselno obravnavati kot del širšega ekosistema. Pri konceptu temeljnih modelov se poudarja, da model ni izolirana komponenta, temveč del širše verige, ki sega od podatkov in predhodnega učenja do prilagajanja in uporabe v konkretni aplikaciji [2].

Poenostavljeno lahko sodoben pogovorni sistem z LLM predstavimo kot več zaporednih komponent:

uporabnik → obdelava uporabnikovega vhoda → sestavljanje konteksta → LLM → preverjanje oz. obdelava izhoda → odgovor uporabniku

Pri naprednejšem sistemu se med posamezne korake vključijo dodatni moduli. Sistem lahko pred generiranjem pridobi relevantno znanje iz zunanje podatkovne zbirke, prebere podatke iz uporabnikovega profila, izbere ustrezno systemsko navodilo ali uporabi dodatna orodja. Po generiranju lahko rezultat še preveri glede varnosti, pravilnosti ali drugih zahtev.

Takšna razdelitev je za kulturno prilagodljive sisteme zelo pomembna, saj pomeni, da kulturnega mehanizma ni treba vključiti neposredno v osnovne parametre LLM-ja. Kulturno informacijo je mogoče dodati na različnih mestih celotne procesne verige.

2.4.2 Predhodno učenje in prilagajanje modela

LLM-ji so praviloma najprej predhodno naučeni (angl. pre-trained) na velikih količinah besedilnih podatkov. Namen predhodnega učenja je pridobiti splošne jezikovne in semantične predstavitve, ki jih je nato mogoče uporabiti pri različnih nalogah. Veliki generativni modeli so pokazali, da se lahko z rastjo modela in količine podatkov pojavijo zmožnosti, ki omogočajo izvajanje novih nalog z malo primeri ali celo samo na osnovi besedilnega navodila [21]. Predhodno naučen model pa še ni nujno primeren za neposredno pogovorno uporabo. Model, katerega osnovna učna naloga je napovedovanje naslednjega žetona, nima samodejno določenega cilja, da mora uporabniku slediti, podati varen odgovor ali upoštevati njegova navodila. Zaradi tega sodobni pogovorni modeli vključujejo nadaljnje faze prilagajanja.

Dodatno se lahko uporabijo podatki o človeških preferencah in povratnih informacijah, s katerimi se vedenje modela usmerja proti odzivom, ki jih ocenjevalci zaznavajo kot ustrežnejše in uporabnejše. Primer takšnega večstopenjskega pristopa, ki vključuje nadzorovano prilagajanje in učenje s človeškimi povratnimi informacijami, predstavlja InstructGPT [22].

Za to raziskovalno delo je pomembno predvsem, da s takšnim prilagajanjem osnovni LLM postane bolj primeren za pogovorno interakcijo, vendar to samo po sebi še ne zagotavlja kulturne prilagodljivosti. Če podatki za prilagajanje ne pokrivajo dovolj kulturno različnih primerov oz. če so preference ocenjevalcev kulturno homogene, se lahko v pogovornem modelu ohranijo ali celo okrepijo preference določenega kulturnega okolja [7], [8].

2.4.3 Generiranje na osnovi LLM v kulturno prilagodljivem sistemu

V nadaljevanju tega dela bo pogosto uporabljen pojem generiranje na osnovi LLM (angl. LLM-based generation). S tem ni mišljen poseben model kulturne prilagodljivosti, temveč način delovanja sistema, pri katerem LLM predstavlja generativno komponento, ki pripravi končni jezikovni odziv.

Pri osnovnem sistemu lahko proces generiranja poenostavljeno predstavimo kot funkcijo: $\text{odziv} = \text{LLM}(\text{uporabniško vprašanje} + \text{kontekst pogovora} + \text{navodila})$

Pri kulturno prilagodljivem sistemu pa lahko vhodni kontekst poenostavljeno razširimo: $\text{odziv} = \text{LLM}(\text{uporabniško vprašanje} + \text{zgodovina pogovora} + \text{domensko znanje} + \text{kulturno znanje} + \text{navodila za prilagoditev})$

Razlika je pomembna. V drugem primeru LLM ni nujno ponovno naučen. Kulturna prilagodljivost lahko nastane tako, da komponente okoli osnovnega modela določijo, katere informacije model prejme pred generiranjem in na kakšen način so te informacije predstavljene. Isti domensko pravilen odgovor je tako mogoče z uporabo istega osnovnega LLM-ja kulturno prilagoditi npr. z izbiro drugačnih primerov, stopnje formalnosti, načina naslavljanja ali poudarka na posamezniku oz. skupnosti. Domensko znanje pri tem določa predvsem, kaj mora sistem povedati, kulturni kontekst pa, kako, komu in v kakšni obliki naj vsebino predstavi.

2.4.4 Kontekstno okno in pogovorni spomin

Pri pogovornem sistemu je pomemben tudi kontekst predhodne interakcije. Model pri vsakem novem odzivu praviloma prejme določeno količino predhodnega pogovora. Največja količina informacij, ki jih lahko model v enem generacijskem koraku obravnava, je omejena s kontekstnim oknom (angl. context window) [23].

To omogoča, da se odziv prilagaja informacijam, ki jih je uporabnik podal v prejšnjih sporočilih. Če uporabnik npr. pove, da želi manj formalne odgovore ali popravi napačno kulturno predpostavko sistema, je mogoče to informacijo vključiti v nadaljnji kontekst. S tem se pojavi možnost dinamične prilagodljivosti skozi pogovor. Vendar zgodovina pogovora sama po sebi še ni dolgoročni spomin. Če želi sistem preference oz. pomembne informacije o uporabniku ohraniti skozi več ločenih pogovorov, potrebuje dodatno komponento za shranjevanje in izbiro relevantnih informacij. Pri kulturno prilagodljivem sistemu bi lahko takšna komponenta hranila potrjene uporabnikove preference, vendar je treba pri tem posebej upoštevati zasebnost in nevarnost ustvarjanja nespremenljivih oz. stereotipnih kulturnih profilov.

Pomembno je zato razlikovati med:

- kontekstom trenutnega pogovora,
- kratkoročnim stanjem uporabnika in
- morebitnim dolgoročnim uporabniškim profilom.

Takšno razlikovanje bo pozneje pomembno pri predlogu kulturnega stanja oz. kulturnega profila sistema.

2.4.5 LLM kot jedro širše modularne arhitekture

Za kulturno prilagodljive pogovorne sisteme je najbolj uporabno razumeti LLM-je kot generativno jedro širše modularne arhitekture. To pomeni, da osnovnemu modelu ni treba samostojno opravljati vseh nalog. Posamezne funkcije lahko prevzamejo specializirane komponente.

Takšna arhitektura lahko npr. vsebuje:

- osnovni LLM za generiranje naravnega jezika,
- komponento za upravljanje zgodovine pogovora,
- domensko zbirko znanja,
- kulturno zbirko znanja,
- mehanizem za priklic ustreznih informacij,
- uporabniški oz. kulturni profil,
- komponento za sestavljanje poziva,
- varnostni oz. kontrolni mehanizem ter
- komponento za vrednotenje oz. preverjanje generiranega odgovora.

Tak pristop omogoča, da se posamezne komponente spreminjajo neodvisno od osnovnega modela. Če se npr. spremeni določena zdravstvena smernica ali se v kulturno zbirko vključijo nove informacije, ni nujno ponovno naučiti celotnega LLM. Prav tako je mogoče isti osnovni model povezati z različnimi kulturnimi in domenskimi zbirkami glede na področje uporabe. Takšno ločevanje je pomembno tudi za analizo pregledanih raziskav, saj omogoča razlikovanje med tipom pogovornega sistema in uporabljenim modelom na eni strani ter tehničnim mehanizmom, ravno prilagoditve in virom personalizacije na drugi. Tako je mogoče ugotavljati, ali kulturno vedenje izvira iz samega LLM-ja ali iz dodatnih komponent sistema.

Za potrebe nadaljnjega dela je zato pomembno izhodišče, da pojma kulturno prilagodljiv LLM in kulturno prilagodljiv pogovorni sistem z LLM nista nujno enaka. Prvi bi lahko pomenil model, katerega notranji parametri oz. učni proces so bili namensko prilagojeni kulturnim podatkom. Drugi pa lahko uporablja splošen LLM in kulturno prilagodljivost doseže z zunanjimi komponentami. Prav razlikovanje med tema dvema možnostma je pomembno za analizo mehanizmov in ravni kulturnega prilagajanja v pregledani literaturi.

2.5 Mehanizmi kulturnega prilagajanja

Na podlagi predstavljene modularne zasnove je mogoče kulturno prilagajanje izvajati z več različnimi tehničnimi mehanizmi. Ti se med seboj ne izključujejo in jih je mogoče združevati v hibridni sistem. Pri njihovi primerjavi je pomembno razlikovati med mehanizmom prilagoditve in ravnjo sistema, na kateri se prilagoditev izvaja oz. izrazi.

Pozivno prilagajanje je npr. mehanizem, ki deluje na vhodu v LLM, medtem ko lahko končni rezultat opazimo kot spremembo tona ali komunikacijskega sloga. Priklicno podprto generiranje (angl. Retrieval-Augmented Generation, v nadaljevanju RAG) je mehanizem za priklic zunanega znanja, vendar se lahko uporablja tako za domensko kot tudi za kulturno prilagajanje. Fino nastavljanje pa prilagoditev premakne globlje v sam model, ker spreminja njegove parametre oz. dodatne učljive komponente.

2.5.1 Pozivno prilagajanje

Eden najpreprostejših načinov prilagajanja LLM-jev je spreminjanje poziva, ki ga model prejme pred generiranjem odgovora. Poziv lahko vsebuje navodilo o nalogi, želenem načinu odgovarjanja, vlogi sistema, jeziku, ciljni skupini ali drugih omejitvah. Pri pozivnem prilagajanju (angl. prompt-based adaptation) se osnovni parametri modela ne spreminjajo, temveč se spremeni vhodni kontekst, na podlagi katerega model generira odgovor.

Sodobni LLM-ji so posebej primerni za takšen način prilagajanja, ker so po učenju s sledenjem navodilom sposobni svoje vedenje spreminjati glede na opis naloge oz. zahtevan način odziva [22]. Širši pregled pozivnih metod pokaže, da lahko ustrezno oblikovani pozivi omogočajo prilagajanje modelov različnim nalogam brez ponovnega učenja njihovih parametrov [11].

Pri kulturnem prilagajanju lahko poziv vsebuje npr. navodila:

- kateri jezik oz. register naj sistem uporablja,
- kako formalno naj nagovarja uporabnika,
- kakšen komunikacijski slog je primeren,
- katere kulturno občutljive teme naj obravnava previdneje,
- ali naj razlago oblikuje bolj individualno ali družinsko oz. skupnostno,
- katere vrste primerov naj uporablja ali se jim izogiba.

Primer neposrednega kulturnega pozivanja predstavlja raziskava Tao et al., kjer so avtorji modelu podali kulturno specifičen kontekst in preverjali, ali se njegove vrednostne usmeritve približajo odgovorom prebivalcev posameznih držav. Rezultati so pokazali, da lahko kulturno pozivanje pri novejših GPT-modelih izboljša kulturno usklajenost, vendar učinek ni bil enak pri vseh državah. To pomeni, da pozivno prilagajanje lahko vpliva na kulturno vedenje modela, vendar samo po sebi ne predstavlja zanesljivega ali univerzalnega kulturnega mehanizma [8].


Glavna prednost pozivnega prilagajanja je njegova preprostost. Ker ni treba ponovno učiti modela, je mogoče isto osnovno arhitekturo hitro prilagoditi več kulturnim okoljem. Kulturna pravila je mogoče tudi razmeroma enostavno popravljati oz. posodabljati.

Slabost pa je, da je takšno prilagajanje odvisno od sposobnosti osnovnega modela, da navodilo pravilno interpretira in mu sledi. Če kulturna informacija v njegovem predhodnem znanju ni dobro zastopana ali če je poziv preveč splošen, npr. samo »odgovori kulturno primerno«, model nima dovolj informacij za kakovostno prilagoditev.

Zato je pri kulturno prilagodljivih sistemih smiselno razlikovati med splošnim kulturnim pozivom in strukturiranim kulturnim pozivom. Prvi zgolj zahteva kulturno občutljivo vedenje, drugi pa modelu poda konkretne parametre, npr. komunikacijski slog, raven formalnosti, občutljivost teme, dovoljene oz. nezaželenе predpostavke in relevantne kulturne informacije.

2.5.2 Priklicno podprto generiranje

Drugi pomemben pristop je RAG. Osnovna ideja RAG-a je, da LLM pri ustvarjanju odgovora ni omejen samo na informacije, shranjene v njegovih parametrih. Pred generiranjem se iz zunanjega vira poiščejo relevantne informacije, ki se nato vključijo v kontekst modela [10]. Osnovno arhitekturo pristopa RAG sestavljata priklicni in generativni del, pri čemer se relevantni dokumenti iz zunanjega indeksa uporabijo kot dodaten kontekst pri generiranju odgovora, kot prikazuje slika 2.2 [10].



Slika 2.2 Osnovna arhitektura priklicno podprtega generiranja [10]

V izvirni arhitekturi priklicni del sestavljata kodirnik poizvedbe in indeks dokumentov, generator pa pridobljene dokumente skupaj z vhom uporabi pri tvorjenju izhoda. Za kulturno prilagodljiv sistem je pomembno predvsem to, da lahko zunanji indeks poleg domenskega vsebuje tudi kulturno relevantno znanje [10].

Poenostavljen potek RAG-a lahko predstavimo kot:

uporabnikovo vprašanje → iskanje relevantnega znanja → izbrane informacije → LLM → odgovor

Zunanji vir je lahko zbirka dokumentov, podatkovna zbirka, enciklopedija, zbirka smernic, lokalni informacijski vir ali namensko pripravljena baza znanja. Pri sodobnih implementacijah se dokumenti pogosto razdelijo na manjše segmente, ki se pretvorijo v vektorske predstavitve. Tudi uporabnikova poizvedba se pretvori v vektor, nato pa sistem poišče vsebinsko podobne segmente in jih vključi v kontekst generiranja.

Za kulturno prilagajanje je RAG posebej zanimiv, ker omogoča, da se kulturno znanje shrani zunaj osnovnega modela. Kulturna zbirka lahko vsebuje:

- lokalne komunikacijske norme,
- kulturno relevantne primere,
- informacije o občutljivih temah,
- lokalno terminologijo,
- smernice, pridobljene s sodelovanjem ciljne skupnosti,
- lokalne običaje in družbene norme,
- kulturno specifične scenarije,
- priporočene in nezaželeni načini formuliranja odgovorov.

Vzporedno lahko sistem uporablja ločeno domensko zbirko znanja, v kateri so npr. zdravstvene smernice, izobraževalne vsebine ali drugi strokovni podatki.

Sistem lahko zato pri enem vprašanju pridobi dve različni vrsti informacij:

- domensko znanje → kaj je vsebinsko pravilno in
- kulturno znanje → kako naj se vsebina primerno predstavi

To je posebej pomembno pri nalogah, kjer se strokovno dejstvo ne spreminja glede na kulturo, lahko pa se močno razlikuje primeren način njegovega posredovanja.


Velika prednost RAG-a je možnost posodabljanja znanja brez spremembe uteži osnovnega modela. Če se spremeni določena lokalna smernica ali se na podlagi nove uporabniške raziskave dopolnijo kulturna priporočila, je mogoče spremeniti samo zunanjo zbirko.

RAG pa ima tudi svoje omejitve. Kakovost končnega odgovora je močno odvisna od kakovosti priklica relevantnih informacij. Če sistem poišče napačno kulturno informacijo ali informacijo za napačno skupino, lahko končni odgovor postane manj primeren. RAG zato sam po sebi ne rešuje problema kulturne prilagodljivosti, temveč zahteva ustrezno strukturiran kulturni vir in mehanizem za določanje relevantnega kulturnega konteksta [24].

2.5.3 Fino nastavljanje in PEFT

Kulturno prilagajanje je mogoče izvesti tudi na ravni parametrov modela s finim nastavljanjem. Pri tem se predhodno naučen LLM dodatno uči na manjši namenski zbirki podatkov, da bi njegovo vedenje prilagodili določeni nalogi, domeni ali načinu komuniciranja.

Pri polnem finem nastavljanju se spreminja velik del ali vsi parametri modela. Takšen postopek je pri velikih modelih računsko zahteven, zato se pogosto uporabljajo metode parametrskega učinkovitega finega nastavljanja (angl. parameter-efficient fine-tuning, v nadaljevanju PEFT). Eden najbolj razširjenih PEFT-pristopov je prilagoditev nizkega ranga (angl. Low-Rank Adaptation, v nadaljevanju LoRA). LoRA parametrizira posodobitev uteži z dvema manjšima učljivima matrikama nizkega ranga, medtem ko osnovna matrika uteži ostane zamrznjena. Tako je mogoče model prilagoditi z bistveno manj učljivimi parametri in manjšimi računskimi zahtevami. Pri metodi LoRA se predhodno naučena matrika uteži ohrani zamrznjena, prilagoditev pa se predstavi z dvema manjšima učljivima matrikama nizkega ranga, kot prikazuje slika 2.3 [12].



Slika 2.3 Nizkorangirana parametrizacija pri metodi LoRA [12]

Če predhodno naučeno matriko uteži označimo z W_0 , lahko LoRA njeno prilagoditev predstavi kot nizkorangirano posodobitev $\Delta W = BA$. Izhod plasti je zato mogoče zapisati kot [12]:

Enačba 2.2 Posredovanje skozi plast z nizkorangirano prilagoditvijo LoRA [12]

$$h = W_0x + \Delta Wx = W_0x + BAx, B \in \mathbb{R}^{d \times r}, W_0 \in \mathbb{R}^{d \times k}, A \in \mathbb{R}^{r \times k}, r \ll \min(d, k)$$

Pri tem W_0 med učenjem ostane zamrznjena, matriki A in B pa vsebujeta učljive parametre. Ker je njun notranji rang r bistveno manjši od dimenzij osnovne matrike, je število parametrov, ki jih je treba prilagoditi, veliko manjše kot pri polnem finem nastavljanju [12].

Pri kulturni prilagodljivosti lahko fino nastavljanje uporabimo, če imamo kakovostno zbirko kulturno specifičnih dialogov, odgovorov ali preferenčnih podatkov. Model se lahko npr. uči:

- uporabljati določen lokalni komunikacijski slog,
- pravilneje presojati kulturne norme,
- uporabljati kulturno specifično terminologijo,
- generirati bolj ustrezne primere,
- se izogibati pogostim kulturnim napakam.

Primer takega pristopa je CultureLLM, kjer so bili modeli fino nastavljeni z namensko pripravljenimi kulturnimi podatki [20]. Prednost finega nastavljanja je, da prilagoditev ni odvisna samo od navodil v posameznem pozivu. Kulturni vzorci postanejo del vedenja prilagojenega modela. To je lahko koristno, kadar mora sistem določeno vedenje izvajati zelo pogosto in dosledno.

Vendar je ta pristop zahtevnejši. Potrebna je ustrezna kulturna podatkovna zbirka, pri čemer slaba ali preveč homogena zbirka lahko model dodatno stereotipizira. Poleg tega je spremembe težje posodabljanje kot pri zunanjem kulturnem viru. Če želimo podpreti več različnih kultur, se pojavi tudi vprašanje, ali potrebujemo več ločenih adapterjev oz. modelov ali en skupni kulturno prilagodljiv model. Zato fino nastavljanje ni nujno najboljša prva izbira za sistem, pri katerem želimo veliko prilagodljivost med različnimi uporabniki.

2.5.4 Aplikacijska in vsebinska plast

Kulturna prilagodljivost se lahko izvede tudi povsem zunaj samega LLM-ja na ravni aplikacijske logike. Aplikacija lahko npr. glede na uporabnikov kontekst izbere:

- drugo vsebinsko enoto,
- drugo zaporedje vprašanj,
- drugačne primere,
- drugo različico izobraževalnega gradiva,
- kulturno specifičen vir,
- drugačen pogovorni scenarij.

V takšnem sistemu LLM ni nujno glavni nosilec kulturnega prilagajanja. Aplikacija najprej določi, katera vsebina je primerna za določeno ciljno skupino, model pa jo nato predstavi v naravnem jeziku. Tak pristop je bil v pregledanih raziskavah zelo pogost.

Prednost aplikacijskega pristopa je velika nadzorovanost. Razvijalec lahko jasno določi, katera kulturna vsebina se uporablja in v katerih okoliščinah. Tak sistem je tudi lažje testirati kot popolnoma generativno rešitev. Slabost je lahko manjša fleksibilnost. Če je večina kulturnih odločitev vnaprej določena, sistem ni nujno resnično dinamično prilagodljiv, ampak je lahko predvsem kulturno lokaliziran.

2.5.5 Persona in interakcijska plast

Kulturna prilagoditev se pogosto izraža tudi na ravni persone in komunikacijskega vedenja sistema. V tem primeru se osnovna vsebina lahko ohrani, spremeni pa se način, kako jo sistem poda uporabniku.

Prilagoditev lahko vključuje:

- formalnost,
- stopnjo neposrednosti,
- uporabo vpljudnostnih oblik,
- stopnjo empatije,
- izbiro zaimkov,
- način samonanašanja sistema,
- ton,
- persono,
- glas,
- kulturno relevantne izraze in metafore.

Pri tem je pomembno, da persona ni samo vizualna ali slogovna lastnost. Način, kako sistem komunicira, lahko vpliva na zaupanje, sprejemljivost in pripravljenost uporabnika za nadaljnjo interakcijo. Kulturno neustrezen ton lahko zmanjša uporabnikovo zaupanje tudi takrat, ko je podana informacija dejansko pravilna.

Vendar tudi tukaj obstaja nevarnost stereotipizacije. Če sistem avtomatsko izbere persono samo na podlagi uporabnikove države ali etnične skupine, lahko namesto personalizacije ustvari karikaturu kulture. Zato mora biti interakcijska prilagoditev po možnosti povezana z dejanskimi preferencami uporabnika.

2.5.6 Kulturni profil oz. stanje uporabnika

Če želimo sistem narediti dejansko prilagodljiv, mora imeti mehanizem, ki določi, kateri kulturni kontekst je v trenutni situaciji relevanten. Takšno komponento lahko konceptualno opišemo kot kulturni profil ali kulturno stanje uporabnika.

Kulturni profil lahko vsebuje relativno stabilne informacije, npr.:

- jezik,
- regijo,
- lokalno okolje,
- prostovoljno izraženo pripadnost skupnosti.

Kulturno stanje pa lahko vključuje bolj dinamične spremenljivke:

- želeno stopnjo formalnosti,
- komunikacijski slog,
- občutljivost trenutne teme,
- preference glede razlage,
- predhodne uporabnikove popravke,
- trenutno stopnjo negotovosti glede kulturne prilagoditve.

Pomembno je, da takšnega profila ne razumemo kot trditev, da sistem »pozna kulturo uporabnika«. Bolj smiselno ga je obravnavati kot množico signalov in preferenc, ki jih sistem lahko uporabi pri prilagajanju.

2.5.7 Hibridni pristop

Posamezni opisani mehanizmi imajo različne prednosti in omejitve, zato se pri kulturnem prilagajanju med seboj ne izključujejo. V istem sistemu je mogoče npr. združiti zunanji vir kulturnega in domenskega znanja, priklic z RAG-om, pozivno prilagajanje, uporabniški kontekst ter dodatno preverjanje generiranega odgovora. Takšen hibridni pristop omogoča, da različne komponente opravljajo različne naloge: RAG zagotavlja relevantno zunanje znanje, pozivna plast določa način njegove uporabe, LLM pa tvori končni jezikovni odziv.

2.5.8 Primerjava pristopov

Tabela 2.2 Primerjava mehanizmov kulturnega prilagajanja

Pristop	Kje se prilagajanje izvede	Ali se uteži LLM spremenijo?	Glavna prednost	Glavna omejitev
Pozivno prilagajanje	vhod/kontekst LLM	Ne	hitro in enostavno prilagajanje	odvisno od osnovnega modela in kakovosti poziva
RAG	zunanja plast znanja	Ne	aktualno in nadzorovano kulturno/domensko znanje	odvisnost od kakovosti priklica
Fino nastavljanje	parametri modela	Da	bolj stabilno naučeno vedenje	potrebuje kakovostne podatke in dodatno učenje
LoRA/PEFT	dodatni oz. omejeni parametri	Ne, učijo se dodatni parametri	manjši strošek kot polno fino nastavljanje	še vedno potrebuje učne podatke
Aplikacijska prilagoditev	aplikacijska/vs ebinska plast	Ne	velika nadzorovanost	lahko ostane statična lokalizacija
Persona/interakcija	izhodna/interakcijska plast	Ne	neposreden vpliv na uporabniško izkušnjo	tveganje površinskega ali stereotipnega prilagajanja
Hibridni pristop	več ravni	Po potrebi	združuje nadzor, znanje in fleksibilnost	večja kompleksnost sistema

3 Metodologija raziskave

3.1 Zasnova pregleda obsega literature

Raziskava je bila izvedena kot pregled obsega literature, katerega namen je sistematično pregledati in kartirati obstoječe raziskave na področju kulturno prilagodljivih klepetalnikov in drugih pogovornih sistemov AI. Pregled obsega literature je primeren predvsem za raziskovalna področja, ki so konceptualno ali metodološko heterogena, saj omogoča pregled uporabljene terminologije, raziskovalnih pristopov, tehnologij, metod vrednotenja in raziskovalnih vrzeli, ne da bi bil njegov primarni cilj statistično združevanje učinkov posameznih raziskav [13].

Takšna metodološka zasnova je primerna za obravnavano področje, ker pojem kulturne prilagodljivosti v pogovornih sistemih ni enotno opredeljen. Kot je bilo predstavljeno v teoretičnem delu, literatura uporablja več sorodnih pojmov, med drugim kulturno ozaveščenost, kulturno občutljivost, kulturno ustreznost, kulturno odzivnost in kulturno usklajenost. Raziskave se razlikujejo tudi po vrsti pogovornega sistema, uporabljenih modelih, načinu implementacije kulturnih značilnosti, domeni uporabe, eksperimentalni zasnovi in uporabljenih metrikah. Zaradi te heterogenosti in predvsem zaradi opisne narave zastavljenih raziskovalnih vprašanj statistično združevanje rezultatov z meta-analizo ni bilo primerno.

Metodološki proces je sledil splošnim fazam pregleda obsega literature, ki vključujejo določitev raziskovalnih vprašanj, iskanje relevantnih raziskav, izbor raziskav, strukturirano ekstrakcijo oz. kartiranje podatkov ter sintezo in predstavitev ugotovitev [13], [25].

Pri poročanju o procesu identifikacije in izbora raziskav so bila upoštevana priporočila razširitve PRISMA za preglede obsega literature, PRISMA-ScR. Postopek izbora je zato prikazan tudi s PRISMA-diagramom, ki omogoča sledljiv prikaz števila zapisov skozi posamezne faze pregleda [14].

Analiza ni bila omejena samo na vprašanje, ali določen sistem vključuje kulturno komponento, temveč je bila ekstrakcija načrtovana tako, da omogoča primerjavo različnih načinov konceptualizacije, implementacije in vrednotenja kulturne prilagodljivosti. Za vsako vključeno raziskavo so bili zato med drugim analizirani način opredelitve kulture, uporabljeni model oz. sistem, ciljne kulturne dimenzije, tehnični mehanizem prilagajanja, uporabljeni viri znanja, način vrednotenja, metrike, eksperimentalna zasnova, človeški udeleženci ter omejitve in raziskovalne vrzeli. Takšna struktura neposredno sledi desetim raziskovalnim vprašanjem, določenim v uvodnem poglavju.

3.2 Iskalna strategija in podatkovne baze

3.2.1 Zasnova iskalne strategije

Iskalna strategija je bila oblikovana okoli dveh osnovnih konceptualnih sklopov:

1. pogovorni sistemi AI in
2. kulturna prilagodljivost.

Prvi sklop je zajemal angleške izraze, povezane s klepetalniki in pogovornimi sistemi, kot so *chatbot*, *conversational agent*, *dialogue system*, *conversational AI*, *virtual assistant*, *voice assistant* in *AI assistant*. Drugi sklop je zajemal izraze, kot so *cultural adaptation*, *cultural awareness*, *cultural sensitivity*, *cultural responsiveness*, *cultural alignment* in *cultural appropriateness*. Natančna sintaksa poizvedb je bila prilagojena funkcionalnostim posamezne podatkovne baze.

Iskanje je bilo izvedeno v štirih bibliografskih podatkovnih bazah:

- Scopus,
- Web of Science Core Collection,
- IEEE Xplore in
- PubMed.

Izbor baz je bil namenoma interdisciplinaren. Scopus in Web of Science omogočata široko pokritost znanstvene literature, IEEE Xplore je posebej pomemben za tehnične in inženirske raziskave pogovornih sistemov, PubMed pa je bil vključen zaradi pokritosti zdravstvenih, psiholoških in vedenjskih aplikacij pogovornih sistemov. Vsa iskanja so bila izvedena 16. 4. 2026.

3.2.2 Omejitve iskanja

Pri iskanju so bile uporabljene naslednje praktične omejitve:

- jezik publikacije: angleščina,
- obdobje objave: 2021–2026,
- vrsta publikacije: znanstveni članki, pregledni članki in konferenčni prispevki oz. prispevki v konferenčnih zbornikih,
- najmanj dva citata.

Časovna omejitev je bila izbrana zato, ker je glavni cilj pregleda kartiranje sodobnega razvoja kulturno prilagodljivih pogovornih sistemov v obdobju hitrega razvoja nevronske generativne modelov in LLM-jev. Zahteva po najmanj dveh citatih je bila uporabljena kot praktični filter za zmanjševanje števila manj uveljavljenih zadetkov. Število citatov je bilo določeno na podlagi citatnega podatka, prikazanega v posamezni bibliografski bazi ob izvedbi iskanja 16. 4. 2026.

Pri tej omejitvi je treba opozoriti na metodološko pomanjkljivost: najnovejše raziskave, zlasti raziskave iz let 2025 in 2026, so imele do datuma iskanja bistveno krajši čas za pridobivanje citatov. Prag dveh citatov zato lahko izloči relevantne nove raziskave, kar predstavlja eno izmed omejitev tega pregleda.

3.2.3 Rezultati iskanja po podatkovnih bazah

Po uporabi navedenih omejitev je bilo pridobljeno:

Tabela 3.1 Rezultati iskanja po bibliografskih podatkovnih bazah

Podatkovna baza	Način iskanja	Število zapisov
Scopus	Advanced Search / TITLE-ABS-KEY	101
Web of Science Core Collection	Advanced Search / TS	73
IEEE Xplore	Advanced Search / metadata	19
PubMed	Title/Abstract / [tiab]	17
Skupaj	/	210

Največ zapisov je bilo pridobljenih iz baze Scopus, sledila je Web of Science Core Collection. IEEE Xplore in PubMed sta prispevala manjše, vendar vsebinsko specifične sklope zapisov.

3.3 Vključitvena in izključitvena merila

Za strukturiranje meril upravičenosti je bil uporabljen okvir populacija – koncept – kontekst (angl. Population – Concept – Context, v nadaljevanju PCC) [26]. V tem pregledu so bile komponente PCC opredeljene na naslednji način:

Tabela 3.2 Opredelitev elementov PCC v raziskavi

Element PCC	Opredelitev v raziskavi
Populacija	klepetalniki in drugi pogovorni sistemi AI
Koncept	kulturna prilagodljivost in sorodni koncepti
Kontekst	katerokoli področje uporabe pogovornega AI-ja

Med pogovorne sisteme so bili vključeni klepetalniki, pogovorni agenti, dialoški sistemi, virtualni pomočniki in glasovni pomočniki. Koncept kulturne prilagodljivosti je bil namenoma opredeljen širše in je zajemal tudi kulturno ozaveščenost, občutljivost, odzivnost, usklajenost in kulturno ustreznost. Kontekst ni bil omejen na eno domeno. Med možnimi področji so bili zdravstvo, izobraževanje, jezikovno učenje, duševno zdravje, podpora uporabnikom in splošni pogovorni sistemi.

3.3.1 Vključitvena merila

V pregled so bile vključene raziskave, ki so izpolnjevale naslednje pogoje:

- obravnavale so klepetalnik ali drug pogovorni sistem umetne inteligence,
- eksplicitno so obravnavale kulturno dimenzijo pri zasnovi, implementaciji, personalizaciji, usklajevanju, prilagajanju ali vrednotenju sistema,
- vsebovale so dovolj informacij za odgovor na vsaj eno od zastavljenih raziskovalnih vprašanj, npr. glede opredelitve kulture, implementacijskega mehanizma, uporabljenega vira, vrednotenja, udeležencev ali raziskovalnih omejitev,
- bile so objavljene kot znanstveni članek, pregledni članek ali konferenčni prispevek oz. prispevek v konferenčnem zborniku,
- bile so napisane v angleškem jeziku,
- objavljene so bile med letoma 2021 in 2026,
- pri izvedbi praktičnega iskanja so imele najmanj dva citata.

3.3.2 Izključitvena merila

Iz pregleda so bile izključene raziskave, ki:

- niso obravnavale pogovornega sistema umetne inteligence,
- so kulturo omenile samo površinsko, brez povezave z zasnovo, implementacijo ali vrednotenjem sistema,
- so obravnavale druge vrste AI-sistemov, npr. priporočilne sisteme ali robotiko brez relevantne pogovorne komponente,
- so kulturno kompetentnost ali kulturno ozaveščenost obravnavale samo na splošni teoretični ravni brez povezave s pogovorno umetno inteligenco,
- so bile uredniška besedila, pisma, diplomska ali doktorska dela, posterji, knjižne recenzije oz. druge vrste publikacij zunaj določenega nabora,
- po pregledu razpoložljivega celotnega besedila niso vsebovale dovolj informacij za zanesljivo presojo upravičenosti ali ekstrakcijo relevantnih podatkov.

Posebej pomembno merilo je bila dejanska povezava med kulturo in pogovornim sistemom. Sama omemba kulture ali dejstvo, da je bila raziskava izvedena v določeni državi, nista bila zadostna razloga za vključitev. Kulturna dimenzija je morala biti povezana z zasnovo, prilagajanjem, vsebino, vedenjem ali vrednotenjem pogovornega sistema.

3.4 Postopek izbora raziskav


Izbor raziskav je potekal v več zaporednih fazah. Najprej so bili rezultati iz vseh štirih podatkovnih baz združeni v skupno zbirko. Ker je bila ista raziskava lahko indeksirana v več podatkovnih bazah, je bila pred vsebinskim pregledom izvedena deduplikacija. Skupno je bilo identificiranih 210 zapisov. V fazi deduplikacije je bilo odstranjenih 84 podvojenih zapisov, tako da je za pregled naslovov in povzetkov ostalo 126 enoličnih zapisov. V naslednji fazi so bili pregledani naslovi in povzetki vseh 126 zapisov glede na

vnaprej določena vključitvena in izključitvena merila. V tej fazi je bilo izključenih 69 zapisov, za 57 raziskav pa je bilo predvideno pridobivanje celotnega besedila. Za dve raziskavi celotnega besedila ni bilo mogoče pridobiti. Zato je bilo na ravni celotnega besedila glede upravičenosti ocenjenih 55 raziskav. Po pregledu celotnih besedil so bile dodatno izključene štiri raziskave, ki niso izpolnjevale končnih vključitvenih meril. Končni vzorec pregleda tako obsega 51 raziskav.

Pregled naslovov, povzetkov in celotnih besedil je bil izveden individualno. Kadar odločitev o vključitvi ali izključitvi posameznega zapisa ni bila enoznačna, je bila presoja ponovljena večkrat s časovnim zamikom, s čimer se je skušal zmanjšati vpliv posamezne trenutne presoje na končno odločitev. Posebej dvoumni primeri so bili ponovno pregledani na podlagi celotnega besedila. V posameznih primerih je bil kot dodatna pomoč pri interpretaciji uporabljen tudi ChatGPT (OpenAI), vendar orodje ni samostojno odločalo o vključitvi ali izključitvi raziskav. Uporaba orodja je bila omejena na dodatno preverjanje interpretacije posebej dvoumnih primerov in ni vključevala samodejnega presejanja zapisov ali sprejemanja končnih odločitev. Vse končne odločitve so bile sprejete na podlagi vnaprej določenih vključitvenih in izključitvenih meril.

Pri dveh raziskavah, označenih z internima identifikatorjema R0067 in R0152, celotno besedilo ni bilo dostopno, zato nista bili vključeni v končno ekstrakcijo. Končna ekstrakcijska zbirka vsebuje 51 raziskav. Pri poznejši vsebinski analizi je bilo 42 raziskav uvrščenih med raziskave z neposredno osredotočenostjo na kulturno prilagodljivost pogovornih sistemov, 9 pa med raziskave, pri katerih je bila kulturna dimenzija relevantna predvsem za posamezne vidike zastavljenih raziskovalnih vprašanj. Vseh 51 raziskav je izpolnjevalo vnaprej določena vključitvena merila.

Po pregledu celotnih besedil so bile izključene štiri raziskave. Tri so bile izključene, ker kulturna prilagodljivost ni predstavljala osrednjega elementa zasnove, implementacije ali vrednotenja obravnavanega pogovornega sistema. Ena raziskava pa je bila osredotočena predvsem na pristranskost in napake avtomatskega razpoznavanja govora ter ni ustrezala opredeljeni enoti analize pogovornih sistemov.



Slika 3.1 Diagram poteka PRISMA-ScR za identifikacijo, pregled in izbor raziskav, pripravljen skladno s PRISMA-ScR [14]

3.5 Ekstrakcija in kategorizacija podatkov

Za vseh 51 vključenih raziskav je bila izvedena strukturirana ekstrakcija podatkov. Ekstrakcijski obrazec je bil oblikovan neposredno glede na 10 raziskovalnih vprašanj, da je bilo mogoče rezultate različnih raziskav sistematično primerjati. Za vsako raziskavo so bile najprej zabeležene osnovne bibliografske in raziskovalne informacije, med drugim identifikator raziskave, leto objave, področje uporabe, namen raziskave in vrsta raziskave. Nato je bila ekstrakcija razdeljena na več vsebinskih sklopov.

3.5.1 Koncept kulture

Za odgovor na RV1 so bili zajeti:

- uporabljena definicija kulture,
- način operacionalizacije kulture,
- morebitna teoretična podlaga oz. kulturni model.

3.5.2 Sistem in model

Za RV2 so bili zabeleženi:

- vrsta pogovornega sistema,
- družina modela,
- konkretni uporabljeni model oz. modeli,
- modalnost sistema.

3.5.3 Cilj kulturne prilagodljivosti

Za RV3 so bili analizirani:

- dimenzija kulturne prilagodljivosti,
- ciljna kultura oz. ciljna skupina,
- raven prilagoditve.

3.5.4 Implementacija

Za RV4 so bili zabeleženi:

- tehnični mehanizem kulturne prilagoditve,
- mesto oz. faza prilagoditve v sistemu,
- vir personalizacije.

V to skupino sodijo npr. prilagajanje s pozivi, priklic zunanjega znanja, RAG, fino nastavljanje, aplikacijsko oz. vsebinsko prilagajanje ter prilagajanje persone ali interakcijskega sloga.

3.5.5 Viri in orodja

Za RV5 so bili identificirani:

- uporabljene podatkovne zbirke,
- primerjalni nabori,
- kulturni oz. domenski viri,
- orodja in ogrodja,
- vrsta in dostopnost uporabljenega vira.

3.5.6 Vrednotenje in metrike

Za RV6 in RV7 so bili zabeleženi:

- način vrednotenja,
- okolje vrednotenja,
- namen vrednotenja,
- uporabljena metrika oz. test,
- kaj posamezna metrika meri,
- ali gre za tehnično, uporabniško, kulturno ali domensko metriko.

3.5.7 Omejitve in raziskovalne vrzeli

Za RV8 so bile ekstrahirane:

- omejitve, ki jih navajajo avtorji,
- poročana tveganja,
- etični vidiki,
- predlogi prihodnjega dela.

3.5.8 Eksperimentalna zasnova

Za RV9 so bili zabeleženi:

- tip raziskovalne oz. eksperimentalne zasnove,
- primerjane skupine ali pogoji,
- vidik sistema, ki je bil vrednoten,
- število oz. vrsta izvedenih eksperimentov.

3.5.9 Človeški udeleženci

Za RV10 so bili posebej ekstrahirani:

- ali so bili v raziskavo vključeni človeški udeleženci,
- njihova vloga,
- velikost vzorca,
- demografske oz. kulturne značilnosti,
- država oz. ciljna skupina,
- način rekrutacije,
- morebitno nadomestilo udeležencem.

Ekstrakcijski obrazec je tako omogočal ne samo opis posameznih člankov, ampak tudi kasnejšo kvantitativno sintezo pogostosti posameznih modelov, kulturnih parametrov, tehničnih mehanizmov, metrik in raziskovalnih zasnov.

3.6 Dodatna kategorizacija kulturnega in domenskega prostora znanja

Med ekstrakcijo se je pokazala potreba po podrobnejši razčlenitvi kulturnega in domenskega prostora znanja, zato je bil začetni ekstrakcijski obrazec dopolnjen z dodatnimi kategorijami. Pri kulturnem prostoru so bile analizirane informacije, kot so:

- ciljna skupnost oz. identiteta,
- jezik, lokalizacija in register,
- komunikacijske norme in slog,
- formalnost in neposrednost,
- občutljivost teme,
- vprašanja zaupanja, zasebnosti in stigmat,
- kulturne vrednote in identitetno oz. družbeno-kulturno oblikovanje vsebine,
- informacije, pridobljene od ciljnih uporabnikov oz. deležnikov.

Domenski prostor je bil obravnavan ločeno od kulturnega, ker predstavlja drugačno vrsto informacij. Vanj so bile vključene strokovne oz. nalogovne vsebine, npr. zdravstvene informacije, vsebine za duševno zdravje, izobraževalne vsebine, reproduktivno zdravje ali krizno komuniciranje. Takšna ločitev je bila pomembna za kasnejšo analizo vprašanja, ali kulturna prilagoditev vpliva na vsebino, ki jo sistem uporablja, na način predstavitve vsebine ali na oboje. V metodološkem smislu je ta dodatna taksonomija nastala kot del strukturiranega kartiranja rezultatov pregleda in bo podrobneje predstavljena v poglavju rezultatov. Dodatne kategorije niso bile v celoti določene vnaprej, temveč so bile med ekstrakcijo iterativno dopolnjene na podlagi ponavljajočih se vzorcev v pregledanih raziskavah. Končne širše kategorije so bile nato uporabljene za deskriptivno sintezo.

3.7 Analiza in sinteza podatkov

Zaradi velike heterogenosti raziskav glede aplikacijskega področja, modela, načina prilagajanja, ciljne skupine in vrednotenja ni bila izvedena meta-analiza, namesto tega sta bili uporabljeni deskriptivna in tematska sinteza. Deskriptivni kvantitativni del je zajemal predvsem štetje pogostosti:

- posameznih modelov in družin modelov,
- vrst pogovornih sistemov,
- dimenzij kulturne prilagodljivosti,
- tehničnih mehanizmov,
- mest implementacije kulturne prilagoditve,
- kulturnih in domenskih parametrov,
- načinov vrednotenja,
- uporabljenih metrik,
- tipov eksperimentov,
- vključevanja človeških udeležencev.

Kadar je raziskava uporabljala več modelov, metrik ali kulturnih dimenzij, so se posamezne kategorije lahko prekrivale. Ker je lahko posamezna raziskava uvrščena v več kategorij, se kategorije med seboj ne izključujejo. Vsota frekvenc posameznih kategorij zato ni nujno enaka številu vključenih raziskav ($n = 51$). Kvalitativni del sinteze je bil usmerjen predvsem v:

- načine opredeljevanja kulture,
- konkretne načine implementacije kulturne prilagodljivosti,
- razlikovanje med kulturnim in domenskim znanjem,
- omejitve sistemov,
- tveganje stereotipizacije,
- vprašanje statične in dinamične prilagodljivosti,
- stopnjo formalizacije kulturnega konteksta,

- raziskovalne vrzeli in implikacije za prihodnjo arhitekturo kulturno prilagodljivega pogovornega sistema.

Pri analizi uporabljenih metrik je bilo posebej razlikovano med neposrednimi merami kulturnega prileganja in drugimi merami uporabniške, tehnične ali domenske uspešnosti sistema. Med neposredne mere so bile uvrščene metrike, ki so eksplicitno ocenjevale kulturno ustreznost, občutljivost ali soroden kulturni konstrukt, preostale pa so bile obravnavane glede na njihov osnovni namen.

3.8 Obravnava manjkajočih in nejasno poročenih podatkov

Pri ekstrakciji so bile informacije povzete samo takrat, kadar jih je bilo mogoče dovolj jasno določiti iz celotnega besedila raziskave. Če določena raziskava ni navedla uporabljene različice modela, velikosti vzorca, natančnega načina kulturnega prilagajanja, statističnega testa, povezave do podatkovne zbirke ali druge zahtevane informacije, manjkajoča informacija ni bila dopolnjena na podlagi domneve.

Takšne vrednosti so bile označene kot:

- ni navedeno,
- ni jasno oz.
- ni relevantno,

odvisno od posamezne kategorije.

Takšen pristop je bil pomemben predvsem pri modelih in eksperimentalnih podatkih, saj del raziskav ne navede natančnega generativnega jedra oz. različice modela. Podobno v vseh raziskavah niso bili vključeni človeški udeleženci oz. njihovo število ni bilo vedno dovolj jasno navedeno.

4 Rezultati

Od 51 vključenih raziskav jih je bilo 42 neposredno osredotočenih na raziskovalno temo, 9 pa je bilo relevantnih predvsem za posamezna raziskovalna vprašanja. Rezultati so bili analizirani glede na 10 raziskovalnih vprašanj, pri čemer so bili zaradi bolj pregledne predstavitve združeni v tematske sklope. Analiza vključuje značilnosti pregledanih raziskav, operacionalizacijo kulture, uporabljene pogovorne sisteme in modele, dimenzije kulturne prilagodljivosti, tehnične mehanizme implementacije, kulturni in domenski prostor znanja, uporabljene vire, načine vrednotenja, metrike, eksperimentalne zasnove, udeležence ter ugotovljene omejitve in raziskovalne vrzeli.

Ker posamezna raziskava pogosto uporablja več modelov, kulturnih parametrov, tehničnih mehanizmov ali metrik hkrati, se vrednosti v nekaterih kategorijah prekrivajo. Vsota teh kategorij zato ni nujno enaka 51.

4.1 Značilnosti vključenih raziskav

Vključene raziskave so bile objavljene med letoma 2021 in 2025, čeprav je iskalno obdobje segalo do leta 2026. Največ raziskav je bilo objavljenih v zadnjih dveh letih analiziranega obdobja. V letu 2021 sta bili vključeni dve raziskavi, leta 2022 tri, leta 2023 devet, leta 2024 šestnajst in leta 2025 enaindvajset raziskav.

Tabela 4.1 Porazdelitev vključenih raziskav po letu objave

Leto	Število raziskav	Delež
2021	2	3,9 %
2022	3	5,9 %
2023	9	17,6 %
2024	16	31,4 %
2025	21	41,2 %
Skupaj	51	100 %

Rezultati kažejo izrazito povečanje raziskovalne aktivnosti v letih 2024 in 2025, saj je bilo v teh dveh letih objavljenih 37 od 51 oz. približno 72,5 % vseh vključenih del. Raziskave so pokrivalo različna aplikacijska področja. Največ jih je bilo povezanih z duševnim zdravjem oz. dobrim počutjem in s širšim zdravstvom oz. javnim zdravjem. Vsaka od teh skupin je obsegala 14 raziskav. 7 raziskav je bilo povezanih z metodami, podatkovnimi zbirkami ali vrednotenjem LLM-jev in 7 z izobraževanjem. Preostala dela so obravnavala glasovne pomočnike in interakcijo človek–računalnik, krizno komuniciranje, migracije, podporo uporabnikom in druga področja.

Tabela 4.2 Glavna področja uporabe

Področje	Število raziskav
Duševno zdravje in dobro počutje	14
Zdravstvo in javno zdravje	14
Metode, podatkovne zbirke in vrednotenje LLM-jev	7
Izobraževanje	7
Glasovni pomočniki	3
Komuniciranje ob nesrečah	2
Splošno / mešano	2
Migracije in integracija	1
Potrošniške storitve	1

Prevlada zdravstvenih in uporabniško usmerjenih aplikacij kaže, da se kulturna prilagodljivost pogosto obravnava predvsem v situacijah, kjer so način komunikacije, zaupanje in občutljivost vsebine posebej pomembni. Po raziskovalni zasnovi je največji sklop predstavljalo 24 empiričnih raziskav z uporabniki, sledilo je 9 raziskav zasnove in vrednotenja sistema. Vključenih je bilo tudi 5 tehničnih oz. razvojnih raziskav, 3 raziskave podatkovnih zbirk ali primerjalnih naborov ter manjše število preglednih, konceptualnih in protokolarnih del. Vsaka raziskava je bila pri tem razvrščena v eno primarno aplikacijsko področje.

4.2 Opredelitev in operacionalizacija kulture

Analiza je pokazala, da kultura v večini raziskav ni predstavljena kot formalno definiran računski model. Namesto tega je operacionalizirana prek posameznih kulturnih značilnosti oz. signalov, ki jih raziskovalci uporabljajo pri zasnovi, prilagajanju ali vrednotenju pogovornega sistema.

Kulturni prostor je bil v 32 od 51 raziskav implicitno opredeljen, kar pomeni, da so bili kulturni dejavniki vključeni v zasnovo ali vrednotenje sistema, vendar avtorji niso oblikovali jasnega strukturiranega kulturnega modela. V 11 raziskavah je bil kulturni prostor mogoče opredeliti kot delno ekspliciten, samo v 8 pa je bil predstavljen dovolj jasno, da ga je bilo mogoče obravnavati kot eksplicitno strukturirano kulturno komponento.

Tabela 4.3 Stopnja formalizacije kulturnega prostora

Opredelitev kulturnega prostora	Število
Implicitna	32
Delno eksplicitna	11
Eksplicitna	8

Najpogostejši način operacionalizacije kulture je bila splošna kulturna ustreznost oz. občutljivost. Takšno izhodišče je bilo prepoznano v 18 raziskavah. Jezik oz. lokalno okolje sta bila uporabljena kot kulturni približek v 14 raziskavah, informacije, pridobljene neposredno od skupnosti oz. uporabnikov, pa v 13 raziskavah. 11 raziskav je kulturno prilagoditev gradilo okoli konkretno določene ciljne skupine, 8 pa jih je uporabljalo eksplicitno kulturno znanje ali kulturno podatkovno zbirko.

Rezultati kažejo, da je bila kultura v pregledanih pogovornih sistemih večinoma operacionalizirana prek konkretnih značilnosti in signalov, ne pa kot enotna formalna latentna spremenljivka. Jezik, država ali pripadnost skupnosti so pogosto uporabljeni kot začetni signali, vendar jih posamezne raziskave dopolnjujejo z informacijami o komunikaciji, občutljivih temah, vrednotah in pričakovanjih uporabnikov.

Posebej pomembna ugotovitev je, da je bila kulturna operacionalizacija pogosto zasnovana tudi s sodelovanjem ciljne skupnosti. Primer takšnega pristopa predstavljajo raziskave, ki uporabljajo intervjuje, fokusne skupine ali soustvarjanje sistema, npr. »Coimagining the Future of Voice Assistants with Cultural Sensitivity« [27] in »Exploring Cultural and Intergenerational Dynamics in Voice Assistant Design for Chinese Older Adults« [28]. Pri takšnih pristopih del kulturnega znanja izhaja neposredno iz izkušenj ciljnih uporabnikov, ne samo iz vnaprej določenih skupinskih oznak.

Te kategorije predstavljajo način operacionalizacije kulture in se zato ne ujemajo nujno s ciljnimi dimenzijami prilagajanja ali z metrikami vrednotenja, ki so analizirane ločeno v poglavjih 4.4 in 4.8.

4.3 Vrste pogovornih sistemov in uporabljeni modeli

Najpogostejša kategorija sistema je bil klepetalnik, v katero je bilo uvrščenih 32 od 51 raziskav. 8 del je obravnavalo pogovorne agente, 6 glasovne pomočnike, 2 dialoške sisteme in 2 pogovorno umetno inteligenco na splošnejši ravni. Ena raziskava je bila neposredno označena kot LLM-klepetalnik.

Tabela 4.4 Vrste pogovornih sistemov

Vrsta sistema	Število raziskav
Klepetalnik	32
Pogovorni agent	8
Glasovni pomočnik	6
Dialoški sistem	2
Pogovorna AI – splošno	2
LLM-klepetalnik	1

Pri poimensko navedenih modelih izrazito prevladuje družina GPT/ChatGPT, ki je bila ugotovljena v 27 raziskavah. GPT-4, GPT-4o oz. GPT-4.0 so bili navedeni v 15 raziskavah, GPT-3.5 pa v 8. Gemini se je pojavil v 4, družina LLaMA v 3, Wysa v 2, generativno kontradiktorno omrežje (angl. Generative Adversarial Network, v nadaljevanju GAN) oz.

pristopi Wassersteinove generativne kontradiktorne mreže (angl. Wasserstein Generative Adversarial Network, v nadaljevanju WGAN) v 2, BERT in IndicTrans2 pa vsak v 1 raziskavi. Ker so posamezne raziskave primerjale več modelov, se te vrednosti prekrivajo. Po zadnjem ponovnem preverjanju 12 raziskav ni dovolj jasno navedlo konkretnega modela oz. generativnega jedra.

Tabela 4.5 Najpogosteje navedeni modeli in komponente

Model, družina ali komponenta	Število raziskav
GPT / ChatGPT	27
GPT-4 / GPT-4o / GPT-4.0	15
GPT-3.5	8
Gemini	4
RAG / LangChain	3
LLaMA	3
Wysa	2
WGAN / GAN	2
BERT	1
IndicTrans2	1
Generativno jedro ni dovolj jasno navedeno	12

Ti rezultati ne pomenijo, da je GPT najuspešnejši model za kulturno prilagodljivost, temveč predvsem, da je bil najpogosteje uporabljen oz. primerjan. Raziskave uporabljajo različne naloge, kulture, domene in metrike, zato neposredna agregirana primerjava uspešnosti posameznih modelov ni metodološko upravičena. Med tehnično bolj zanimivimi primeri je MenstLLaMA, specializirani LLM za izobraževanje o menstrualnem zdravju v Indiji, ki je bil primerjan z modeli GPT-4o, GPT-4, GPT-3.5, Gemini 1.5 in LLaMA-3 [29]. Drug primer je sistem Saarthi, ki povezuje IndicTrans2 in Gemini za večjezično komunikacijo v indijskem okolju [30].

4.4 Dimenzije kulturne prilagodljivosti

Pregled je pokazal, da so raziskave obravnavale več različnih ciljnih dimenzij kulturnega prilagajanja. Najpogosteje je bila ciljna dimenzija kulturna občutljivost oz. kulturna ustreznost, ki se je pojavila v 19 raziskavah. Sledila je splošna kulturna prilagoditev v 16 raziskavah in prilagajanje konkretni skupini v 11.

Jezik oz. register sta predstavljala eksplicitno dimenzijo prilagajanja v 10 raziskavah. 7 raziskav je obravnavalo afektivni slog oz. empatijo, 5 pa identiteto ali persono sistema. Neverbalna oz. multimodalna kulturna prilagoditev in kulturno znanje kot samostojna ciljna dimenzija sta se pojavila redkeje.

Tabela 4.6 Ciljne dimenzije kulturne prilagodljivosti

Dimenzija	Število raziskav
Kulturna občutljivost / ustreznost	19
Splošna kulturna prilagoditev	16
Prilagajanje ciljni skupini	11
Jezik / register	10
Afektivni slog / empatija	7
Identiteta / persona	5
Neverbalna / multimodalna prilagoditev	1
Kulturno znanje kot samostojna dimenzija	1

Rezultati kažejo, da se je kulturna prilagoditev pogosteje nanašala na način komunikacije in predstavitev vsebine kot na spreminjanje same domenske vsebine odgovora. Pogosti so prilagajanje tona, formalnosti, neposrednosti, izbire primerov in načinov predstavljanja vsebine.

Podrobnejša analiza ekstrahiranih kulturnih značilnosti je pokazala 6 večjih družin parametrov. Ker se posamezne družine med seboj ne izključujejo, je bila lahko ista raziskava uvrščena v več kategorij. Najpogostejša je bila identiteta ciljne skupine oz. skupnosti, prepoznana v 46 raziskavah oz. 90,2 %. Sem sodijo npr. etnična pripadnost, migracijski status, starostna skupina, regija ali druga skupnostna identifikacija.

Interakcijske norme in slog so bile prisotne v 39 raziskavah oz. 76,5 %, signali občutljivosti, zaupanja in ovir pa v 31 oz. 60,8 %. Jezik, lokalizacija ali register so bili prisotni v 20 raziskavah, neposredno vključevanje deležnikov pri opredelitvi kulture v 13, vrednote, identiteta in širše sociokulturno oblikovanje pa v 7 raziskavah.

Tabela 4.7 Družine kulturnih parametrov

Družina kulturnih parametrov	n	Delež
Ciljna skupina / identiteta skupnosti	46	90,2 %
Interakcijske norme / slog	39	76,5 %
Občutljivost / zaupanje / ovire	31	60,8 %
Jezik / lokalno okolje / register	20	39,2 %
Kulturna podlaga, pridobljena od deležnikov	13	25,5 %
Vrednote / identiteta / sociokulturno oblikovanje	7	13,7 %

Pomembno je poudariti, da ti parametri niso enotna standardizirana množica, ki bi jo uporabljalo vseh 51 raziskav. Gre za taksonomijo, oblikovano na podlagi kategorizacije konkretnih parametrov in kulturnih signalov.

4.5 Mehanizmi in ravni implementacije kulturne prilagodljivosti

Rezultati kažejo, da je bila kulturna prilagoditev v pregledanih raziskavah pogosteje implementirana na zunanjih sistemskih ravneh kot z neposredno spremembo jedra modela. Najpogostejša glavna lokacija prilagoditve je bila aplikacijska, delovna oz. vsebinska plast, ki je bila identificirana v 15 raziskavah. V teh sistemih je bila kultura realizirana z izbiro vsebine, lokaliziranimi moduli, delovnim tokom ali zasnovno intervencije.

V 14 raziskavah je bila glavna kulturna komponenta na ravni vmesnika, persone oz. interakcije, kjer se je prilagoditev izražala z načinom govora, persono, glasom, samonanašanjem, tonom ali slogom dialoga.

5 raziskav je uporabljalo LLM kot del aplikacije z dodatnimi zunanjimi kulturnimi ali domenskimi viri. V 4 je bila glavna arhitekturna komponenta zunanji RAG oz. plast znanja, 3 so bile primarno pozivno prilagojene, samo 1 pa je kulturno prilagoditev implementirala neposredno bližje generacijskemu oz. modelnemu jedru. Vsaki raziskavi je bila določena ena primarna lokacija kulturne prilagoditve.

Tabela 4.8 Primarna lokacija kulturne prilagoditve

Lokacija	n
Aplikacijska / procesna / vsebinska plast	15
Vmesnik / persona / interakcija	14
Konceptualno / pregledno / vir	5
LLM-aplikacija z zunanjim prilagajanjem	5
Zunanja RAG / plast znanja	4
Pozivna plast	3
Ni dovolj jasno navedeno	3
Jedro modela / generacijski proces	1
Zunanji modul znanja	1

Ker niso bile analizirane samo glavne arhitekturne ravni, temveč tudi uporabljeni tehnični in razvojni pristopi, so se posamezne kategorije pogosto pojavljale skupaj. RAG je bil identificiran v 24 raziskavah, generiranje na osnovi LLM v 21, izdelava ali uporaba namensko oblikovanega podatkovnega vira v 12, pravila oz. pozivno/vsebinsko prilagajanje v 8, pozivno inženirstvo v 7, participativno oz. soustvarjalno načrtovanje v 6 in fino nastavljanje v 5 raziskavah.

Tabela 4.9 Tehnični in razvojni pristopi, uporabljeni pri kulturnem prilagajanju

Mehanizem	n
RAG	24
generiranje na osnovi LLM	21
Izdelava/uporaba podatkovnega vira	12
Pravila / pozivi / vsebinska prilagoditev	8
Pozivno inženirstvo	7
Soustvarjanje / participativna zasnova	6
Fino nastavljanje	5
Mehanizem ni dovolj jasno opisan	4
GAN-osnovano generiranje	1

Dober primer RAG-pristopa je raziskava »Leveraging Retrieval-Augmented Generation for Culturally Inclusive Hakka Chatbots: Design Insights and User Perceptions«, kjer je RAG uporabljen za kulturno vključujoč Hakka klepetalnik [31]. Primer čistejše pozivne prilagoditve predstavlja »Effects of Language- and Culture-Specific Prompting on ChatGPT«, kjer so primerjani jezikovno in kulturno specifični načini pozivanja [32]. Tudi raziskava »Tailoring Generative AI Chatbots for Multiethnic Communities in Disaster Preparedness Communication: Extending the CASA Paradigm« uporablja različne kulturno in komunikacijsko pogojene različice odzivov [33]. Skupni vzorec torej kaže, da kulturna prilagodljivost običajno nastane kot plast okoli osnovnega modela, ne kot povsem nov LLM.

4.6 Kulturni in domenski prostor znanja

Na podlagi kategorizacije ekstrahiranih podatkov je bilo mogoče analitično razlikovati med kulturnim in domenskim prostorom znanja. Izraza kulturni in domenski prostor znanja sta v tem delu uporabljena kot analitični kategoriji za razvrščanje različnih vrst informacij, opisanih v pregledanih raziskavah. Kulturni prostor je praviloma vseboval informacije, povezane s tem, za koga in na kakšen način naj se sistem prilagodi, domenski prostor pa informacije, potrebne za izvedbo osnovne naloge. Pri kulturnem prostoru je bila najpogostejša struktura množica kulturnih pogojev oz. kulturno pogojena predloga poziva, ki je bila identificirana v 38 od 51 raziskav. 8 raziskav je uporabljalo kulturni korpus oz. zunanji kulturni spomin, 3 so kulturo primarno predstavljale z osebo oz. interakcijskim slojem, 2 pa z neposredno na skupnosti temelječimi pravili.

Tabela 4.10 Struktura kulturnega prostora

Struktura	n
Kulturni pogoji / kulturno pogojena predloga poziva	38
RAG-korpus / zunanji kulturni spomin	8
Persona / slog / vmesnik	3
Pravila, oblikovana na podlagi skupnosti	2

Glede na način uporabe kulturnega konteksta je bilo v 30 raziskavah kulturne informacije mogoče dinamično aktivirati oz. pridobiti ob posamezni poizvedbi, v 15 raziskavah pa so bile določene enkrat za posamezno sejo oz. zahtevo. Samo 3 raziskave so nakazovale možnost spreminjanja kulturnega stanja skozi interakcijo, v 3 primerih pa je bila kulturna prilagoditev predvsem statično vnaprej določena.

Domenski prostor je bil praviloma bolje definiran. V 44 raziskavah je bil ocenjen kot delno ekspliciten in v 7 kot impliciten. Najpogostejša struktura je bila zunanja domenska zbirka oz. spomin za priklic podatkov, ki se je pojavil v 30 raziskavah. 18 raziskav je uporabljalo kuriran domenski vsebinski repozitorij, 3 pa bolj neposredno nalogovno vsebinsko plast. V 19 raziskavah je bilo mogoče dovolj jasno ločiti domensko vsebino od kulturne prilagoditvene plasti, medtem ko v 32 raziskavah meja med njima ni bila dovolj jasna.

Primer raziskave, kjer je zunanji kulturni vir posebej pomemben, je »Cultural Commonsense Knowledge for Intercultural Dialogues« [34], ki obravnava eksplicitno vključevanje kulturnega zdravorazumskega znanja v medkulturne dialoge. Primer izrazito domensko specializiranega pristopa pa je MenstLLaMA, kjer je kulturna prilagoditev povezana z zelo specifičnim področjem menstrualnega zdravja v Indiji [29].

4.7 Podatkovne zbirke, primerjalni nabori in ponovno uporabni viri

Pregled je pokazal veliko heterogenost pri poročanju o podatkovnih zbirkah in drugih ponovno uporabnih virih. 20 raziskav ni navedlo jasnega ponovno uporabnega vira, v 20 pa je glavni zunanji tehnološki vir predstavljal LLM oz. vmesnik za programiranje aplikacij (angl. Application Programming Interface, v nadaljevanju API). Podatkovna zbirka je bila identificirana kot pomemben vir v 10 raziskavah, primerjalni nabor v 6, ponovno uporaben prototip klepetalnika v 5 in RAG cevovod (angl. pipeline) v 2.

Pri 23 raziskavah je bila javna dostopnost podatkovnega nabora ali primerjalnega vira eksplicitno navedena oz. dovolj jasno dokumentirana. 8 raziskav je vsebovalo eksplicitno povezavo do kode oz. repozitorija, 2 do modela, skupno pa je 11 raziskav vsebovalo vsaj 1 neposredno povezavo do ponovno uporabnega vira poleg digitalnega identifikatorja objekta (angl. Digital Object Identifier, v nadaljevanju DOI) članka.

To kaže, da so ponovno uporabni viri sicer prisotni, vendar javno dostopna in standardizirana infrastruktura za kulturno prilagodljivost še ni običajna praksa.

Pomemben primer ponovno uporabnega vira je »MULTI3WOZ: A Multilingual, Multi-Domain, Multi-Parallel Dataset for Training and Evaluating Culturally Adapted Task-Oriented Dialog Systems«. MULTI3WOZ predstavlja večjezični, večdomenski in vzporedni podatkovni vir za učenje in vrednotenje kulturno prilagojenih nalogovno usmerjenih dialoških sistemov [35]. Drugi pomembni primeri so podatkovni ali kulturni viri v raziskavah MenstLLaMA [29], »Cultural Commonsense Knowledge for Intercultural Dialogues« [34] in različnih kulturno specifičnih RAG-sistemih.

4.8 Načini vrednotenja in uporabljene metrike

Vrednotenje kulturno prilagodljivih pogovornih sistemov je bilo izrazito heterogeno. 11 raziskav je bilo primarno kvalitativnih oz. participativnih in 11 tehnično oz. avtomatsko vrednotenih. 6 raziskav je uporabljalo eksperimente oz. poskuse, 6 ankete, 4 so bile primarno usmerjene v uporabnost oz. sprejemljivost in 2 sta uporabljali mešane metode. Po končnem ponovnem preverjanju je bilo za vseh 51 raziskav mogoče določiti vsaj uporabno kategorijo raziskovalne oz. evalvacijske metode, vendar se je raven podrobnosti med članki močno razlikovala.

Tabela 4.11 Glavne skupine vrednotenja

Vrsta vrednotenja	n
Kvalitativno / participativno	11
Tehnično / avtomatsko	11
Drugo	9
Eksperiment / poskus	6
Anketa	6
Uporabnost / sprejemljivost	4
Mešane metode	2
Pregled / sinteza	2

Še več razlik je bilo ugotovljenih pri uporabljenih metrikah. Po končni normalizaciji je bila najpogostejša širša družina lestvice uporabnosti sistema (angl. System Usability Scale, v nadaljevanju SUS) oz. uporabnost, ki je bila prepoznana v 37 raziskavah. Vključenost oz. interakcija je bila merjena v 33 raziskavah, pravilnost oz. natančnost v 27 in sprejemljivost oz. izvedljivost prav tako v 27. Kategorija »SUS/uporabnost« vključuje tako raziskave, ki so uporabile standardizirano lestvico SUS, kot raziskave, ki so uporabnost vrednotile z drugimi instrumenti. Vrednost 37 zato ne pomeni, da je bila v vseh teh raziskavah uporabljena prav lestvica SUS.

Klinični oz. psihološki izidi so bili uporabljeni v 25 raziskavah, kulturna občutljivost oz. kulturna ustreznost pa neposredno v 21. Prav tako je bilo zaupanje oz. kredibilnost merjeno v 21 raziskavah.

Tabela 4.12 Najpogostejše družine metrik

Družina metrik	n	Osnovni pomen
SUS / uporabnost	37	uporabnost, enostavnost uporabe, uporabniška izkušnja
Vključenost / interakcija	33	uporaba, nadaljevanje interakcije, sodelovanje
Točnost / vsebinska pravilnost	27	vsebinska ali nalogovna pravilnost
Sprejemljivost / izvedljivost	27	sprejem sistema v ciljnem okolju
Klinični / psihološki izidi	25	depresija, tesnoba, stres, osamljenost, dobro počutje
Kulturna občutljivost / ustreznost	21	neposredna kulturna ustreznost odziva
Zaupanje / kredibilnost	21	zaupanje v sistem in njegove odzive
Odnos / namera / vedenje	21	pripravljenost za uporabo oz. vedenjska sprememba
Zadovoljstvo / preference	17	zadovoljstvo in primerjava različic
Natančnost / priklic / F1	14	tehnična zmogljivost
Kakovost generiranja	9	npr. BLEU, ROUGE, BERTScore in sorodne ocene
Kvalitativne teme	2	kvalitativne ugotovitve iz intervjujev/fokusnih skupin

Tu je pomembna interpretativna razlika. Ocene kulturne občutljivosti oz. ustreznosti so bile obravnavane kot neposredne mere kulturnega prileganja, kadar je bila metrika eksplicitno zasnovana za ocenjevanje kulturne ustreznosti odziva. SUS, vključenost, zaupanje in sprejemljivost lahko predstavljajo pomembne posredne kazalnike, vendar visoka uporabnost sama po sebi še ne dokazuje, da je sistem kulturno ustrezen. Podobno točnost (angl. accuracy), natančnost (angl. precision), priklic (angl. recall) in F1 praviloma merijo tehnično uspešnost, ne pa kulturnega prileganja, razen kadar je naloga neposredno zasnovana tako, da ocenjuje kulturno pravičen odgovor.

Pri zdravstvenih raziskavah so bile uporabljene tudi standardizirane psihološke lestvice, med drugim CES-D, GAD-7, UCLA Loneliness Scale, PHQ-2, PHQ-9 in druge domensko specifične meritve.

Primer predstavlja »Effect of a Cognitive Behavioral Therapy–Based AI Chatbot on Depression and Loneliness in Chinese University Students: Randomized Controlled Trial With Financial Stress Moderation«, kjer so bili poleg uporabnosti uporabljeni CES-D, GAD-7 in UCLA Loneliness Scale [36].

4.9 Eksperimentalne zasnove in udeleženci

Najpogostejša raziskovalna zasnova je bila empirična raziskava z uporabniki, ki je predstavljala 24 od 51 raziskav. 9 del je bilo zasnovanih kot razvoj in vrednotenje sistema, 5 kot tehnične oz. razvojne raziskave, 3 kot prispevki, osredotočeni na podatkovne zbirke ali primerjalne nabore (angl. benchmark), preostala pa kot pregledna, konceptualna ali protokolarna dela.

V analiziranih raziskavah so bili uporabljeni:

- randomizirani oz. kontrolirani poskusi,
- eksperimentalne primerjave,
- ankete,
- testi uporabnosti,
- fokusne skupine,
- intervjuji,
- soustvarjalne delavnice,
- strokovno vrednotenje,
- tehnični primerjalni nabori (angl. technical benchmark) in
- raziskave z mešanimi metodami.

To se ujema tudi s končno ekstrakcijo testov in udeležencev. V 32 raziskavah so bili udeleženci oz. ciljna populacija predvsem dejanski končni uporabniki. 10 raziskav ni imelo ločenega vzorca človeških udeležencev, 5 jih je uporabljalo druge oz. mešane skupine, 2 sta bili primarno usmerjeni v strokovnjake ali deležnike, v 2 pa vloge ni bilo mogoče dovolj jasno določiti. Natančno numerično velikost vzorca je bilo mogoče zanesljivo ekstrahirati v 17 raziskavah. Skupaj so te raziskave zajemale 2.535 udeležencev, mediana velikosti vzorca je znašala 61, najmanjši vzorec je imel 11, največji pa 472 udeležencev. Povprečna velikost vzorca med teh 17 raziskav je bila približno 149 udeležencev, vendar je zaradi velikega razpona med vzorci mediana bolj reprezentativna mera tipične velikosti.

Raziskave so vključevale zelo različne populacije:

- študente,
- bolnike,
- mladostnike,
- starejše odrasle,
- negovalce,
- migrante in begunce,

- etnične manjšine,
- skupnosti moških, ki imajo spolne odnose z moškimi (angl. men who have sex with men, v nadaljevanju MSM),
- zdravstvene strokovnjake in
- različne skupnosti oz. deležnike.

Primer večjega vzorca je »Exploring Acceptability of AI-Enabled Voice Assistants and Digital AI Humans in Healthcare: A Cross-Sectional Survey«, kjer je sodelovalo 472 odraslih oseb iz Združenega kraljestva [37]. Pri »Exploring the Contingent Effect of Cultural Tailoring of GenAI Chatbots on Multiethnic Members' Disaster Information Seeking and Preparation Attitude: A Cross-Group Comparison« je bilo vključenih 346 udeležencev iz hispanske in afroameriške skupnosti [38].

V raziskavi »Design, Development and Usability of an Educational AI Chatbot for People with Haemophilia in Senegal« je sodelovalo 57 uporabnikov [39], medtem ko je raziskava z mladimi migranti »Into the Unknown: Leveraging Conversational AI in Supporting Young Migrants' Journeys Towards Cultural Adaptation« uporabljala bistveno manjši kvalitativni vzorec 11 udeležencev [40]. Razpon primerov tako sega od večjih kvantitativnih raziskav z več sto udeleženci do manjših kvalitativnih in participativnih raziskav.

4.10 Omejitve, tveganja in raziskovalne vrzeli v pregledani literaturi

Pregled je pokazal več ponavljajočih se omejitev obstoječega področja. Prva je pomanjkljiva tehnična dokumentacija. Tudi po dodatnem ponovnem pregledu celotnih besedil je bilo mogoče dovolj jasno določiti poimenovan model oz. generativno jedro v 39 od 51 raziskav, medtem ko ga 12 ni dovolj natančno razkrilo. Pri 14 raziskavah je po ponovnem preverjanju ostala vsaj ena pomembnejša tehnična negotovost.

Druga omejitev je reproducibilnost. Samo 8 raziskav je vsebovalo jasno povezavo do kode oz. repozitorija, veliko podatkovnih virov pa ni bilo neposredno ponovno uporabnih. To otežuje neposredno ponovitev in primerjavo raziskav. Tretja omejitev je heterogena operacionalizacija kulture. V večini raziskav kulturni prostor ni formalno definiran, kultura pa se pogosto predstavlja prek jezika, države ali pripadnosti določeni ciljni skupini. Takšno poenostavljanje predstavlja tveganje, da sistem prilagajanje enači z lokalizacijo ali uporabniku pripisuje značilnosti povprečnega predstavnika skupine.

Četrta omejitev je pomanjkanje standardiziranega vrednotenja kulturne prilagodljivosti. Čeprav je bila kulturna občutljivost oz. ustreznost neposredno merjena v 21 raziskavah, so bile pogosto uporabljene tudi posredne mere, kot so SUS, zadovoljstvo, sprejemljivost in zaupanje. Posledično enake oznake »kulturno prilagodljiv sistem« med raziskavami ne pomenijo nujno enake stopnje dokazane kulturne ustreznosti.

Pomembna raziskovalna vrzel je tudi časovna oz. longitudinalna prilagodljivost. Glede na časovno dinamiko je bilo 33 raziskav razvrščenih v kategorijo dinamičnega oz. omejeno dinamičnega prilagajanja, 15 raziskav je bilo omejenih na prilagajanje na ravni

posamezne seje ali zahteve, pri 3 raziskavah pa ni bilo jasno opisanega dinamičnega prilagajanja med uporabo.

Še izrazitejši rezultat je bil ugotovljen pri spominu. Samo 1 od 51 raziskav je dovolj jasno opisala uporabo zgodovine uporabnika in spomina seje kot dela prilagajanja. V 50 raziskavah tak mehanizem ni bil poročan. Zato je večina obstoječih sistemov bolj podobna kulturno pogojenemu odzivanju ob posamezni poizvedbi kot dejanskemu dolgoročnemu učenju uporabnikovih kulturnih preferenc. Podobno je bil ekspliciten povratni mehanizem med uporabo redek. V 16 raziskavah so bili uporabniki oz. deležniki vključeni pri razvoju sistema, vendar ni bilo jasno, da bi ta povratna informacija postala del dinamičnega prilagajanja med uporabo.

Rezultati tako kažejo, da so ključne odprte raziskovalne vrzeli:

- bolj eksplicitna in večdimenzionalna predstavitev kulture,
- ločevanje med skupinskim kulturnim kontekstom in individualnimi preferencami,
- preprečevanje stereotipizacije,
- razvoj dinamičnega kulturnega stanja skozi pogovor,
- boljša uporaba uporabniške zgodovine in povratnih informacij,
- standardizirano neposredno vrednotenje kulturnega prileganja,
- boljša reproducibilnost sistemov, podatkov in pozivov,
- primerjalno vrednotenje kulturno prilagojene in neprilagojene različice istega sistema.

5 Smernice in predlog arhitekture kulturno prilagodljivega pogovornega sistema

5.1 Izhodišča za zasnovo sistema

Pregled 51 raziskav kaže, da kulturno prilagodljivih pogovornih sistemov ni mogoče opisati z eno samo arhitekturo ali enim univerzalnim načinom prilagajanja. Raziskave uporabljajo različne modele, kulturne značilnosti, domene in mehanizme prilagajanja, zato na podlagi obstoječih rezultatov ni mogoče določiti enega modela, ki bi bil splošno najboljši za vse kulturne in aplikacijske kontekste.

V analiziranih raziskavah so se kulturne značilnosti najpogosteje pojavljale na ravni aplikacijske logike, vsebine, persone in interakcijskega sloga. Aplikacijska oz. vsebinska plast je bila primarna lokacija kulturne prilagoditve v 15 raziskavah, interakcijska oz. persona plast pa v 14. Nasprotno je bila prilagoditev, ki je neposredno posegala v jedro modela oz. generacijski proces, kot primarna lokacija identificirana samo v eni raziskavi.

To kaže, da kulturna prilagodljivost v obstoječi literaturi pogosteje predstavlja sistemsko lastnost kot lastnost samega osnovnega LLM-ja. Model lahko predstavlja generativno jedro, medtem ko kulturno vedenje določajo dodatne komponente, ki izbirajo ustrezne informacije, sestavljajo poziv, prilagajajo vsebino ali spreminjajo komunikacijski slog.

Drug pomemben rezultat je velika heterogenost pri operacionalizaciji kulture. Kulturni prostor je bil pogosto samo implicitno ali delno eksplicitno predstavljen, medtem ko so bili najpogostejši kulturni parametri povezani s ciljno skupnostjo oz. skupnostno identiteto, interakcijskimi normami in slogom, občutljivostjo in zaupanjem, jezikom oz. registrom, informacijami, pridobljenimi od deležnikov, ter vrednotami in sociokulturnim kontekstom.

Takšen rezultat kaže, da kulturo ni smiselno modelirati samo z eno spremenljivko, kot sta država ali jezik. Kulturni kontekst je bolje razumeti kot večdimenzionalno množico signalov, pri čemer posamezni signal ni nujno relevanten za vsako interakcijo. Pomembna je tudi razlika med kulturnim in domenskim znanjem. Analizirane raziskave kažejo, da je domensko znanje praviloma bolj eksplicitno in strukturirano kot kulturno. Domenski prostor lahko npr. vsebuje zdravstvene smernice, izobraževalno gradivo ali informacije o duševnem zdravju, kulturni prostor pa način komunikacije, občutljive teme, lokalne primere in pričakovanja določene skupnosti.

Na tej podlagi je mogoče oblikovati osnovno konceptualno razlikovanje. Domensko znanje določa predvsem, kaj mora sistem povedati, kulturno znanje pa, kako, komu in pod katerimi kulturnimi pogoji naj to pove. Ta razlika predstavlja eno izmed ključnih izhodišč predlagane arhitekture.

5.2 Zahteve za kulturno prilagodljiv pogovorni sistem

Na podlagi rezultatov pregleda je mogoče oblikovati več zahtev, ki bi jih moral izpolnjevati prihodnji kulturno prilagodljiv pogovorni sistem. Prva zahteva je modularnost. Ker kulturno prilagajanje v večini analiziranih raziskav ni bilo vezano neposredno na jedro modela, je smiselno osnovni LLM ločiti od kulturnih in domenskih komponent. Takšna zasnova omogoča spreminjanje kulturnih pravil, virov znanja in uporabniških preferenc brez ponovnega učenja celotnega modela.

Druga zahteva je ločevanje kulturnega in domenskega znanja. Sistem mora znati razlikovati med informacijami, ki določajo pravilnost vsebine, in informacijami, ki določajo kulturno primeren način njene predstavitve. S tem se zmanjša nevarnost, da bi kulturna prilagoditev spreminjala strokovno dejstvo namesto načina njegovega posredovanja. Tretja zahteva je večdimenzionalna predstavitev kulturnega konteksta. Rezultati pregleda kažejo, da kulturne informacije zajemajo bistveno več kot samo nacionalnost ali jezik. Najpogostejše kategorije so vključevale ciljno skupnost, interakcijske norme, občutljivost in zaupanje, jezik oz. register ter informacije, pridobljene neposredno od deležnikov.

Četrta zahteva je dinamičnost. Kulturna prilagoditev ne bi smela biti omejena na vnaprej pripravljeno različico sistema za posamezno državo ali skupino. Sistem bi moral omogočati, da se določene preference med pogovorom spremenijo. Uporabnik lahko npr. jasno pove, da želi bolj neposredno komunikacijo, manj formalno nagovarjanje ali drugačen način razlage. Peta zahteva je upravljanje negotovosti. Sistem ne sme predpostaviti, da iz uporabnikovega jezika, lokacije ali pripadnosti določeni skupini pozna vse njegove kulturne preference. Skupinske informacije so lahko začetna orientacija, ne pa dokončen individualni profil.

Šesta zahteva je sledljivost kulturnega znanja. Kulturna priporočila morajo imeti znan izvor. Posebej pomembni so viri, oblikovani s sodelovanjem ciljne skupnosti, lokalnih strokovnjakov ali drugih deležnikov. Sedma zahteva je preverjanje generiranega odziva, saj že sama uporaba RAG-a ali kulturnega poziva ne zagotavlja, da bo končni odgovor brez stereotipov, neupravičenih predpostavk oz. kulturno neprimernega izražanja.

5.3 Predlagana arhitektura sistema

Na podlagi navedenih zahtev je za nadaljnje doktorsko delo predlagana hibridna modularna arhitektura kulturno prilagodljivega pogovornega sistema. Osnovo sistema predstavlja močan večjezični, za sledenje navodilom prilagojen LLM, ki deluje kot generativna komponenta. Okoli njega so nameščene ločene komponente za upravljanje kulturnega konteksta, domenskega znanja, priklic informacij, sestavljanje pozivov in preverjanje rezultatov. Na podlagi rezultatov pregleda in izpeljanih zahtev je mogoče predlagano arhitekturo kulturno prilagodljivega sistema prikazati s shemo poteka, prikazano na sliki 5.1.



Slika 5.1 Komponente predlagane arhitekture

Slika 5.1 prikazuje, da je kulturna prilagoditev obravnavana kot lastnost celotnega sistema in ne samo osnovnega LLM-ja. Kulturni in domenski prostor znanja sta ločena, njuna uporaba pa je usklajena prek krmilnika prilagajanja, ki določa, kako naj se relevantne informacije vključijo v generiranje odgovora.

5.3.1 Osnovni večjezični LLM

Osrednja generativna komponenta sistema je splošen večjezični LLM, prilagojen sledenju navodilom. Rezultati pregleda ne omogočajo zaključka, da je posamezna družina modelov univerzalno najboljša za kulturno prilagodljivost. Čeprav je bila družina GPT/ChatGPT najpogostejše uporabljena, to kaže predvsem njeno razširjenost, ne pa dokazano superiornost za kulturne naloge.

Zato predlagana arhitektura ni vezana na en konkretni model. Osnovni LLM mora predvsem:

- dobro slediti navodilom,
- podpirati več jezikov,
- omogočati dovolj veliko kontekstno okno,
- kakovostno uporabljati pridobljene zunanje informacije in
- omogočati zamenjavo brez preoblikovanja celotne arhitekture.

Takšna modularnost omogoča tudi prihodnje primerjanje različnih osnovnih modelov pod enakimi kulturnimi pogoji.

5.3.2 Domenski prostor znanja

Domenski prostor znanja vsebuje informacije, ki so potrebne za vsebinsko pravilno izvajanje naloge.

Glede na področje uporabe lahko vsebuje:

- strokovne smernice,
- preverjena dejstva,
- postopke,
- pogosto zastavljena vprašanja,
- izobraževalne vsebine,
- klinične oz. strokovne protokole,
- lokalne predpise in
- druge avtoritativne domenske vire.

Pri zdravstvenem sistemu bi tako domenska baza vsebovala zdravstveno znanje, ne pa pravil o tem, kako se mora določeni skupnosti to znanje predstaviti.

Za vsak dokument oz. segment bi bilo smiselno hraniti tudi metapodatke, kot so:

- domena,
- poddomena,
- jezik,
- država oz. jurisdikcija,
- avtoriteta vira,
- datum oz. različica,
- ciljna uporabniška skupina in
- vrsta naloge.

Takšna struktura omogoča filtriran priklic relevantnih informacij.

5.3.3 Kulturni prostor znanja

Kulturni prostor znanja je ločen od domenskega in vsebuje informacije, povezane s kulturno ustreznim načinom komunikacije.

V njem so lahko shranjeni:

- komunikacijske norme,
- formalnost,
- neposrednost,
- lokalne jezikovne posebnosti in register,
- kulturno relevantni primeri,
- občutljive oz. tabu teme,

- vprašanja stigme,
- dejavniki zaupanja,
- vrednostni oz. družinski okvirji,
- priporočeni načini komuniciranja in
- načini izražanja, ki se jim je priporočljivo izogniti.

Takšna zasnova je neposredno povezana z rezultati pregleda, kjer so bile med najpogostejšimi kulturnimi kategorijami skupnostna identiteta, interakcijske norme, občutljivost in zaupanje ter jezik/register. Kulturna zbirka ne sme temeljiti samo na splošnih spletnih opisih posameznih držav. Prednost je treba dati virom, ki izvirajo iz ciljnih skupnosti, intervjujev, fokusnih skupin, participativnega načrtovanja, lokalnih strokovnjakov in empiričnih raziskav.

Takšen pristop je mogoče povezati z raziskavami, kot so »Cultural Commonsense Knowledge for Intercultural Dialogues«, kjer je kulturno znanje obravnavano kot ekspliciten zunanji vir [34], ter »Leveraging Retrieval-Augmented Generation for Culturally Inclusive Hakka Chatbots«, kjer je zunanji vir znanja uporabljen v RAG-sistemu [31]. Za posamezen zapis v kulturnem prostoru znanja je smiselno hraniti tudi metapodatke, ki omogočajo sledljivost, kontekstualizacijo in poznejše posodabljanje kulturnih informacij.

Tabela 5.1 Predlagani metapodatki kulturnega zapisa

Metapodatek	Primer
Skupnost / okolje	slovensko, Hakka, korejsko ...
Jezik / register	slovenščina, formalno
Kontekst	zdravstvo
Komunikacijska norma	posredna razlaga občutljive teme
Občutljiva tema	duševno zdravje
Priporočeno vedenje	uporabi nevtralnno, nestigmatizirajočo terminologijo
Nezaželene predpostavke ali vedenje	domnevanje družinske strukture
Izvor	fokusna skupina / strokovnjak / raziskava
Stopnja podpore z dokazi	visoka / srednja / nizka
Datum preverjanja	datum zadnjega preverjanja zapisa
Potrjeno s skupnostjo	da / ne

Takšna struktura omogoča, da so kulturne informacije sledljive, preverljive in posodobljive, hkrati pa je mogoče razlikovati med njihovim izvorom, kontekstom uporabe in stopnjo zanesljivosti.

5.3.4 Kulturno stanje uporabnika

Pomembna razširitev glede na številne obstoječe pristope je uvedba kulturnega stanja uporabnika. Namen kulturnega stanja ni določiti, »kateri kulturi uporabnik pripada«, ampak hraniti informacije, ki so lahko relevantne za trenutno prilagajanje. Kulturno stanje posameznega uporabnika bi lahko bilo predstavljeno kot strukturiran nabor parametrov, ki se med uporabo dopolnjujejo in posodablajo. Primer takšnega zapisa prikazuje tabela 5.2

Tabela 5.2 Primer strukture kulturnega stanja uporabnika

Parameter	Primer
Jezik	slovenščina
Lokalno okolje	Slovenija
Želeni register komunikacije	neformalen
Neposrednost	srednja
Slog empatije	podporen, ne pretirano čustven
Družinska oz. skupnostna usmerjenost	po potrebi
Občutljive teme	glede na uporabnikovo navedbo
Način razlage	kratek in konkreten
Želeni primeri	lokalni
Dodatne preference	uporabnikove eksplicitne zahteve
Vir informacije	uporabnik / povratna informacija med sejo / privzeta vrednost skupnosti
Stopnja zaupanja	visoka / srednja / nizka

Stopnja zaupanja se pri tem nanaša na zanesljivost posameznega podatka o uporabnikovi preferenci ali kulturnem kontekstu, ne na splošno zaupanje uporabnika v sistem. Neposredno izražene preference uporabnika bi imele višjo prednost kot privzete vrednosti, izpeljane iz skupinske pripadnosti. Posebej pomemben je vir posamezne informacije. Sistem mora razlikovati med:

- neposredno izražena preferenca uporabnika – uporabnik je preferenco navedel neposredno,
- povratna informacija znotraj seje – preferenca je bila razvidna iz neposrednega popravka ali odziva med pogovorom,
- privzeta vrednost skupnosti – začetna vrednost, določena za posamezno skupnost.

Neposredno izražena uporabnikova preferenca mora imeti prednost pred skupinsko privzeto vrednostjo. Tako se lahko npr. uporabnik iz kulturnega okolja, za katerega sistem uporablja bolj formalno komunikacijo kot začetno nastavitve, sam odloči, da želi neformalno komunikacijo. Sistem mora njegovo individualno izbiro upoštevati namesto skupinske predpostavke.

5.3.5 Analizator poizvedbe

Pred priklicom kulturnega znanja mora sistem oceniti, ali je kulturna prilagoditev pri trenutnem vprašanju sploh potrebna. Vsako vprašanje ne zahteva vseh kulturnih parametrov. Pri vprašanju: »Koliko je 15×4 ?« kulturna prilagoditev praktično ni relevantna. Pri vprašanju: »Kako naj se s svojo družino pogovorim o težavah z duševnim zdravjem?« pa so lahko relevantni:

- družinske norme,
- stigma,
- način komuniciranja,
- neposrednost,
- empatija in
- lokalni kontekst.

Analizator poizvedbe mora zato določiti:

- domeno vprašanja,
- občutljivost teme,
- kulturne dimenzije, ki so relevantne,
- ali potrebujemo domenski priklic,
- ali potrebujemo kulturni priklic.

S tem se prepreči nepotrebno kulturno označevanje vsake uporabnikove zahteve.

5.3.6 Dvojni RAG

Predlagana arhitektura uporablja dva logično ločena procesa priklica informacij. Domenski RAG poišče informacije, ki zagotavljajo vsebinsko pravilnost odgovora. Kulturni RAG poišče smernice, ki določajo primeren način predstavitve glede na trenutni kulturni kontekst. Oba vira se nato posredujeta sestavljalniku poziva, vendar morata biti jasno označena, npr.:

- domenski kontekst – preverjena strokovna dejstva
- kulturne smernice – kulturno relevantna komunikacijska priporočila

Takšno ločevanje zmanjša možnost, da bi model kulturno priporočilo interpretiral kot strokovno dejstvo ali obratno. RAG je pri tem razumljen kot mehanizem utemeljevanja oz. priklica relevantnega konteksta, ne kot samostojen mehanizem kulturne inteligence.

5.3.7 Krmilnik kulturnega prilagajanja

Med kulturnim stanjem, RAG-om in osnovnim modelom je predlagana dodatna komponenta, in sicer krmilnik prilagajanja (angl. adaptation controller).

Njegova naloga je odločanje:

- katere kulturne dimenzije so relevantne,
- katere informacije iz kulturnega stanja uporabiti,
- katere filtre uporabiti pri kulturnem RAG-u,
- ali je stopnja zaupanja v kulturno informacijo dovolj visoka,
- ali mora sistem vprašati uporabnika za dodatno informacijo,
- kateri komunikacijski slog izbrati,
- ali je treba aktivirati strožje varnostno preverjanje.


Krmilnik je pomemben zato, ker zgolj shranjevanje velike količine kulturnih parametrov ne pomeni kakovostnejše prilagoditve. Nasprotno, vključevanje vseh kulturnih informacij v vsak odgovor lahko poveča stereotipizacijo in zmanjša naravnost komunikacije. Naloga krmilnika je zato predvsem izbira minimalnega relevantnega kulturnega konteksta.

5.3.8 Sestavljalnik poziva

Ko so pridobljeni domenski in kulturni podatki, sistem sestavi strukturiran poziv za osnovni LLM. Poziv lahko vsebuje:

- sistemske in varnostne zahteve,
- uporabnikovo vprašanje,
- relevantno zgodovino pogovora,
- domensko znanje,
- kulturne smernice,
- eksplicitne uporabnikove preference,
- navodila glede sloga in tona,
- navodilo, naj model ne ustvarja kulturnih predpostavk, ki niso podprte z informacijami.

Sestavljalnik poziva združi nalogo, domenski kontekst, kulturne smernice, uporabnikove preference in omejitve v enoten strukturiran vhod za osnovni LLM, kot prikazuje slika 5.2.



Slika 5.2 Predlagana struktura končnega poziva za kulturno prilagodljiv pogovorni sistem

Takšna ločitev omogoča, da so strokovna vsebina, kulturno prilagajanje in varnostne omejitve v pozivu predstavljeni kot ločene, sledljive komponente. Primeri kulturnega pozivanja iz literature kažejo, da lahko kulturno pogojeni pozivi spreminjajo vedenje modela, vendar njihov učinek ni vedno enak pri vseh kulturah [8]. Zato je v predlaganem sistemu pozivna plast kombinirana z zunanjim znanjem in eksplicitnim kulturnim stanjem.

5.3.9 Preverjanje generiranega odgovora

Po generiranju bi odgovor prešel še skozi modul za kulturno ustreznost, varnost in utemeljenost. Modul bi preverjal najmanj:

- neupravičeno stereotipizacijo,
- prekomerno posploševanje,
- kulturno neprimeren ton,
- neskladje z uporabnikovimi eksplicitnimi preferencami,
- konflikt med kulturnimi smernicami in strokovnim znanjem,
- nepodprte trditve,
- morebitne varnostne probleme.

Pri zaznani težavi se odgovor lahko:

- popravi,
- ponovno generira ali
- nadomesti z bolj nevtrarno različico.

Pomembno je, da kulturna prilagoditev nikoli ne prevlada nad dejansko pravilnostjo ali varnostjo. Če kulturna preferenca nasprotuje preverjenemu strokovnemu dejstvu, se prilagodi način komunikacije, ne pa dejstvo.

5.3.10 Povratna informacija in prilagajanje skozi čas

Končna komponenta predstavlja uporabnikovo povratno informacijo. Uporabnik lahko npr. pove:

- »Ni treba biti tako formalen.«
- »Ne uporabljal takšnih primerov.«
- »Prosim, odgovori bolj neposredno.«
- »Pri nas se temu reče drugače.«

Takšna informacija je bistveno bolj zanesljiv signal individualne preference kot predpostavka, izpeljana iz nacionalnosti ali jezika. Če uporabnik dovoli shranjevanje teh informacij, se lahko kulturno stanje posodobi in uporabi pri prihodnjih interakcijah. S tem sistem preide iz statične skupinske prilagoditve proti individualni in postopno popravlja kulturni prilagodljivosti.

5.4 Predlagani kulturni parametri

Na podlagi taksonomije, oblikovane iz pregledanih raziskav, bi predlagani začetni kulturni prostor razdelil na šest glavnih skupin.

Tabela 5.3 Predlagani kulturni parametri

Skupina	Primeri parametrov
Jezik in lokalno okolje	jezik, narečje, register, regionalna terminologija
Komunikacijske norme	formalnost, neposrednost, vljudnost, način naslavljanja
Interakcijski slog	dolžina odgovora, razlagalni slog, persona, ton
Občutljivost in zaupanje	stigma, zasebnost, tabu teme, varnost, stopnja zaupanja
Vrednote in socialni kontekst	individualna/družinska usmerjenost, skupnost, relevantni vrednostni okvirji
Individualne preference	eksplicitne uporabnikove preference in popravki

Ni potrebno, da sistem vse te parametre uporablja pri vsakem odgovoru. Njihova relevantnost mora biti določena glede na trenutno vprašanje. Prav tako ni priporočljivo, da bi začetno kulturno stanje vsebovalo veliko število domnev o uporabniku. Primernejši pristop je minimalno začetno kulturno stanje, ki se dopolnjuje samo takrat, kadar je informacija relevantna in dovolj zanesljiva.

5.5 Predlagano vrednotenje sistema

Pregled literature kaže, da se kulturno prilagodljivi sistemi vrednotijo z zelo različnimi metrikami. Med pogosto uporabljenimi so vključenost, uporabnost, natančnost, sprejemljivost, zaupanje in neposredne ocene kulturne občutljivosti oz. ustreznosti.

Neposredne mere kulturne občutljivosti oz. ustreznosti so bile identificirane v 21 raziskavah, pogosto pa so bile uporabljene tudi mere uporabnosti, vključenosti, tehnične pravilnosti in zaupanja. Za vrednotenje predlagane arhitekture zato ena sama metrika ne bi bila dovolj. Najpomembnejši rezultat mora biti neposredna ocena kulturnega prilaganja.

Predlagana primarna merila so:

- kulturna ustreznost,
- kulturna občutljivost,
- spoštljivost,
- relevantnost,
- naravnost komunikacije,
- odsotnost stereotipov.

Sekundarna merila pa:

- zaupanje oz. kredibilnost,
- sprejemljivost,
- uporabnost oz. SUS,
- zadovoljstvo,
- vključenost,
- domenska oz. dejanska pravilnost.

Natančnost oz. tehnična pravilnost mora biti merjena ločeno od kulturnega prilaganja. Kulturno primeren, vendar vsebinsko napačen odgovor ni uspešen odgovor.

5.5.1 Eksperimentalni pogoji

Za oceno dejanskega prispevka mehanizmov kulturnega prilagajanja je smiselno primerjati tri konfiguracije istega sistema. Prvi pogoj predstavlja osnovni LLM brez dodatnega kulturnega prilagajanja, pri katerem uporabniško vprašanje neposredno vstopi v model, rezultat pa je generirani odgovor. Ta pogoj predstavlja izhodiščno primerjalno vrednost. Drugi pogoj predstavlja pozivno prilagajanje, pri katerem se uporabniškemu vprašanju doda kulturni poziv, nato pa LLM generira odgovor. Ta pogoj omogoča oceno, kolikšno stopnjo kulturne ustreznosti je mogoče doseči samo s pozivnim prilagajanjem. Tretji pogoj predstavlja celotno kulturno arhitekturo, v kateri so poleg osnovnega modela vključeni še kulturno stanje uporabnika, kulturni in domenski RAG, krmilnik prilagajanja, strukturirani poziv ter kulturno-varnostni pregled odgovora. Primerjava vseh treh pogojev omogoča presojo, ali in v kolikšni meri celovita modularna arhitektura izboljša kulturno ustreznost v primerjavi z osnovnim LLM-jem in preprostejšim pozivnim prilagajanjem.

Po potrebi se lahko izvedejo tudi ablacijski eksperimenti, npr.:

- brez kulturnega RAG,
- brez krmilnika,
- brez kulturnega stanja uporabnika,
- brez končnega preverjanja,
- RAG brez pozivnega prilagajanja.

S tem je mogoče ugotoviti, katera komponenta dejansko prispeva k izboljšanju rezultatov.

5.5.2 Udeleženci vrednotenja

Na podlagi pregledane literature bi bilo smiselno vključiti dve skupini ocenjevalcev. Ciljni uporabniki lahko ocenijo:

- naravnost,
- relevantnost,
- zaupanje,
- sprejemljivost,
- kulturno ustreznost iz lastnega življenjskega konteksta.

Strokovnjaki oz. kulturno kompetentni ocenjevalci pa lahko bolj sistematično ocenijo:

- stereotipizacijo,
- kulturno občutljivost,
- varnost,
- strokovno pravilnost in
- skladnost z oblikovanimi kulturnimi smernicami.

Kombinacija ocen ciljnih uporabnikov in strokovnih ocenjevalcev bi omogočila celovitejše vrednotenje kot uporaba zgolj avtomatskih metrik.

5.6 Predvideni raziskovalni prispevek arhitekture

Glavni predvideni raziskovalni prispevek predlaganega pristopa ni razvoj novega osnovnega LLM-ja, temveč zasnova eksplicitne, modularne in vrednotljive plasti kulturnega prilagajanja. Predlagana arhitektura povezuje več elementov, ki so v pregledani literaturi pogosto obravnavani ločeno: zmogljiv večjezični LLM, domenski in kulturni prostor znanja, kulturno stanje uporabnika, priklicno podprto generiranje, pozivno prilagajanje, krmilnik prilagajanja, preverjanje generiranega odziva ter uporabniško povratno informacijo.

Ključna razlika glede na statično kulturno lokalizacijo je način obravnave skupinskih kulturnih informacij. Te niso razumljene kot dokončne lastnosti posameznika, temveč kot začetni in negotovi signali, ki jih je mogoče med interakcijo dopolnjevati ali nadomeščati z neposredno izraženimi preferencami uporabnika. Če se skupinska

kulturna predpostavka razlikuje od preference, ki jo uporabnik izrazi neposredno, ima prednost njegova individualna preferenca.

Kulturni kontekst je zato v predlagani arhitekturi predstavljen kot dinamično stanje in ne kot fiksna oznaka uporabnika. Sistem na podlagi trenutno razpoložljivih informacij izbere najprimernejšo komunikacijsko strategijo, vendar jo lahko ob novih informacijah ali uporabnikovi povratni informaciji spremeni. Takšna zasnova bi lahko zmanjšala tveganje stereotipizacije ter omogočila prehod od sistemov, ki so vnaprej prilagojeni posamezni kulturni skupini, k sistemom, ki se med uporabo prilagajajo tudi preferencam posameznega uporabnika.

6 Razprava

V tem poglavju so ugotovitve pregleda interpretirane v širšem kontekstu razvoja kulturno prilagodljivih pogovornih sistemov. Namen ni ponoviti rezultatov posameznih raziskovalnih vprašanj, temveč ugotoviti, kaj skupni vzorci pomenijo za razumevanje kulturne prilagodljivosti, katere tehnične usmeritve se kažejo kot najprimernejše in katere raziskovalne vrzeli ostajajo odprte.

6.1 Kulturna prilagodljivost kot lastnost celotnega sistema

Ena izmed osrednjih ugotovitev pregleda je, da kulturne prilagodljivosti ni smiselno obravnavati samo kot lastnost LLM-ja. V analiziranih raziskavah se je kulturna komponenta najpogosteje pojavljala na aplikacijski oz. vsebinski ravni ter na ravni persone in interakcije. Neposredno poseganje v jedro modela oz. generacijski proces je bilo bistveno redkejše.

Tak rezultat kaže na pomemben premik v načinu razumevanja problema. Vprašanje pri razvoju kulturno prilagodljivega klepetalnika ni nujno samo, kateri LLM izbrati, temveč predvsem, kako organizirati celoten sistem okoli njega. Osnovni model lahko zagotavlja splošno jezikovno in generativno sposobnost, kulturna prilagodljivost pa nastane z izbiro ustreznega znanja, upravljanjem uporabniškega konteksta, prilagajanjem poziva, komunikacijskega sloga in drugih komponent.

To je skladno tudi z rezultatom, da je bila družina GPT/ChatGPT najpogosteje uporabljena v analiziranem korpusu, vendar iz tega ni mogoče zaključiti, da je tudi najboljša za kulturno prilagajanje. Posamezne raziskave se razlikujejo po domenah, ciljnih kulturah, nalogah in metrikah, zato podatki ne omogočajo neposredne primerjave uspešnosti osnovnih modelov.

Za nadaljnji razvoj je zato primernejša modelno neodvisna modularna arhitektura, pri kateri je mogoče osnovni LLM zamenjati, ne da bi bilo treba ponovno zasnovati kulturno stanje uporabnika, podatkovne zbirke in mehanizme prilagajanja.

6.2 Kultura ni ena sama spremenljivka

Druga pomembna ugotovitev je velika heterogenost pri opredeljevanju kulture. V večini analiziranih raziskav kultura ni bila formalizirana kot ekspliciten računski model, ampak je bila predstavljena prek različnih približkov in lastnosti. Najpogostejši kulturni parametri so bili povezani s ciljno skupino oz. skupnostjo, interakcijskimi normami in slogom, občutljivostjo in zaupanjem ter jezikom oz. registrom. Manj pogosto so bile eksplicitno predstavljene vrednote ali formalne kulturne dimenzije.

To podpira ugotovitev raziskave »*Towards Measuring and Modeling 'Culture' in LLMs: A Survey*«, da raziskave kulture v LLM-jih pogosto uporabljajo posamezne kulturne približke namesto enotne definicije kulture [7].

Rezultati tega pregleda kažejo podobno stanje pri pogovornih sistemih. Država, jezik ali pripadnost skupini so lahko uporabni signali, vendar sami po sebi niso dovolj za opis uporabnikovega kulturnega konteksta.

Posebej problematična bi bila arhitektura, ki bi sklepala:

država → kultura → uporabnikovo vedenje.

Tak pristop lahko hitro vodi v stereotipizacijo, saj agregirane skupinske značilnosti prenese neposredno na posameznika. Primernejši je večdimenzionalen pristop, pri katerem so nacionalnost, jezik ali skupnost lahko začetni kontekst, ne pa dokončna opredelitev uporabnika. Individualne preference, izražene neposredno med interakcijo, bi morale imeti prednost pred skupinskimi privzetimi vrednostmi.

6.3 Kulturno prilagojen in kulturno prilagodljiv sistem

Rezultati odpirajo tudi pomembno terminološko vprašanje: ali so vsi sistemi, ki jih literatura opisuje kot kulturno prilagojene oz. kulturno občutljive, dejansko tudi prilagodljivi.

Velik del analiziranih sistemov je bil prilagojen določeni skupnosti že med razvojem. Vsebina, jezik, persona ali potek pogovora so bili npr. zasnovani za določeno državo, etnično skupino ali ciljno populacijo. Tak sistem je lahko zelo dobro kulturno prilagojen, vendar se med uporabo ni nujno sposoben prilagajati različnim posameznikom.

Zato je smiselno razlikovati med:

- kulturno prilagojenim sistemom, pri katerem je prilagoditev določena že med razvojem in
- kulturno prilagodljivim sistemom, ki kulturni kontekst uporablja kot spremenljiv vhod ter svoje vedenje spreminja med uporabo.

Ta razlika postane posebej očitna pri analizi dolgoročnega prilagajanja. Čeprav so bili v številnih raziskavah kulturni pogoji določeni ob posamezni poizvedbi ali seji, je bila eksplicitna uporaba zgodovine uporabnika oz. spomina zelo redka. To kaže, da velik del trenutnih rešitev predstavlja predvsem kulturno pogojeno generiranje, medtem ko je dolgoročna personalizacija na podlagi uporabnikove zgodovine bistveno redkejša. Prav ta razlika predstavlja pomembno raziskovalno priložnost za nadaljnje doktorsko delo.

6.4 Vloga RAG, pozivnega prilagajanja in finega nastavljanja

Pregledani pristopi kažejo, da obstajajo različni načini vključevanja kulture v pogovorni sistem. Med njimi so RAG, pozivno prilagajanje, fino nastavljanje, aplikacijska pravila ter prilagajanje persone in komunikacijskega sloga. Noben posamezen pristop sam po sebi ne reši vseh težav.

Pozivno prilagajanje je fleksibilno in računsko oz. stroškovno manj zahtevno, vendar je njegov učinek odvisen od predhodnega znanja in sposobnosti osnovnega modela.

Raziskave kulturnega pozivanja kažejo, da lahko ustrezen kulturni kontekst spremeni odgovore modela, vendar izboljšanje ni vedno enako za vse kulture [8].

Fino nastavljanje lahko kulturne vzorce globlje vključi v vedenje modela, vendar potrebuje kakovostne kulturne podatke in je težje posodabljati. Poleg tega se pri podpori več kulturnim okoljem pojavi vprašanje, ali potrebujemo več ločenih modelov oz. adapterjev.

RAG omogoča ločitev kulturnega znanja od parametrov osnovnega modela in njegovo sprotno pridobivanje. To je posebej pomembno, kadar želimo kulturne smernice popravljati, razširjati oz. vezati na določen vir. RAG pa sam po sebi ne zna določiti, katera kulturna informacija je za konkretnega uporabnika ustrezna.

Na podlagi sinteze pregledanih pristopov se kot smiselna usmeritev kaže kombinacija različnih mehanizmov: RAG za pridobivanje relevantnega znanja, pozivna plast za usmerjanje generiranja, kulturno stanje za personalizacijo in krmilnik za izbiro relevantnih dimenzij.

To ni rezultat ene same raziskave, temveč arhitekturna sinteza ugotovitev celotnega pregleda.

6.5 Ločevanje kulturnega in domenskega znanja

Ena izmed bolj uporabnih ugotovitev analize je razlikovanje med kulturnim in domenskim prostorom znanja. Domenski prostor je bil v pregledanih raziskavah praviloma bolj eksplicitno strukturiran, medtem ko je bil kulturni pogosto implicitno ali delno formaliziran. Ločevanje obeh vrst informacij je pomembno tudi z vidika varnosti.

Pri zdravstvenem klepetalniku kulturno prilagajanje ne sme pomeniti, da se medicinsko dejstvo spremeni glede na uporabnikovo kulturno okolje. Spremeni se lahko način razlage, izbira primera, stopnja neposrednosti ali način obravnave stigmatizirane teme, medtem ko mora strokovna informacija ostati utemeljena v domenskem viru.

Takšno razlikovanje lahko povzamemo tako: domenska plast je primarno povezana z vsebinsko in strokovno pravilnostjo, kulturna plast pa s kulturno ustreznostjo in načinom predstavitve vsebine.

V realnem sistemu se obe plasti seveda prepletata, vendar njuna logična ločitev omogoča večjo sledljivost. Če je odgovor napačen, je mogoče lažje ugotoviti, ali težava izhaja iz domenskega znanja, kulturnega znanja, priklica ali generiranja.

6.6 Vrednotenje kulturne prilagodljivosti

Eden največjih problemov področja je pomanjkanje enotnega načina vrednotenja. V pregledanih raziskavah so bile pogosto uporabljene uporabnost, vključenost, natančnost, sprejemljivost, zaupanje in neposredne ocene kulturne občutljivosti oz. ustreznosti. V 21 od 51 pregledanih raziskav so bile uporabljene neposredne mere kulturne občutljivosti oz. ustreznosti.

Vendar te metrike ne merijo istega pojava. Visoka ocena SUS pomeni, da je sistem lahko enostaven za uporabo. Ne pomeni pa nujno, da je kulturno ustrezen. Visoka natančnost pomeni, da sistem pravilno rešuje nalogo. Prav tako ne dokazuje kulturne ustreznosti. Tudi visoko zaupanje uporabnika je lahko pomembno, vendar je posredna mera. Zato bi morala biti pri vrednotenju kulturno prilagodljivega sistema neposredna kulturna ustreznost primarni izid, sekundarno pa bi bilo treba spremljati tehnično pravilnost, uporabnost, sprejemljivost, zaupanje in domenske izide.

Posebej pomembna bi bila primerjava istega sistema pod različnimi pogoji, npr. osnovni LLM, kulturni poziv in celotna kulturna prilagoditvena arhitektura. Na ta način bi lahko spremembo v kulturnem prilaganju pripisali konkretni prilagoditveni komponenti.

6.7 Človek kot vir kulturnega znanja

Rezultati kažejo tudi pomembno vlogo ciljnih uporabnikov in drugih deležnikov. V delu raziskav so bili kulturni parametri pridobljeni z intervjuji, fokusnimi skupinami, participativnim načrtovanjem ali soustvarjanjem. Takšen način je posebej pomemben zato, ker zmanjšuje odvisnost od splošnih kulturnih teorij ali sekundarnih opisov skupnosti. Če kulturno zbirko oblikujemo samo iz splošnih spletnih informacij, obstaja nevarnost, da reproducira stereotipe ali zastarele opise.

Vključevanje uporabnikov pa ne rešuje problema popolnoma. Tudi fokusna skupina predstavlja samo omejen vzorec določene populacije. Zato smernic, pridobljenih od skupnosti, ne smemo razumeti kot pravila, ki veljajo za vse člane skupine. Primernejše jih je obravnavati kot empirično podprte začetne smernice, ki jih posameznik lahko prek lastnih preferenc spremeni.

6.8 Tveganje stereotipizacije in etični vidiki

Kulturna personalizacija lahko izboljša relevantnost sistema, hkrati pa ustvari nova tveganja. Največje je stereotipiziranje uporabnika. Če sistem iz omejene informacije, kot je država, sklepa na njegove vrednote, vero, družinsko strukturo ali komunikacijske preference, kulturna prilagodljivost postane oblika avtomatskega profiliranja.

Drugo tveganje predstavlja zasebnost. Kulturno stanje lahko vsebuje občutljive informacije, zlasti kadar vključuje etnično pripadnost, vero, zdravstveni kontekst ali druge osebne lastnosti. Zato dolgoročno shranjevanje kulturnih preferenc zahteva jasen namen, soglasje uporabnika in možnost pregleda oz. izbrisa podatkov.

Tretje tveganje je kulturna zastarelost. Kultura ni statična, zato tudi kulturne zbirke ne smejo biti obravnavane kot nespremenljiva pravila.

Četrto tveganje predstavlja navidezna kulturna kompetentnost. Sistem lahko ustvari zelo naraven in prepričljiv kulturno prilagojen odgovor, čeprav je kulturna predpostavka, na kateri temelji, napačna. Jezikovna tekočnost in naravnost odgovora zato nista dokaz njegove kulturne ustreznosti.

Predlagana arhitektura skuša ta tveganja zmanjšati z:

- uporabo skupinskih informacij samo kot začetnih signalov,
- prednostjo neposredno izraženih uporabnikovih preferenc,
- hranjenjem izvora kulturnega znanja,
- oceno stopnje zaupanja,
- možnostjo nevtralnega odgovora pri negotovosti in
- dodatnim pregledom generiranega odziva.

6.9 Raziskovalne vrzeli in nadaljnje delo

Na podlagi rezultatov je mogoče izpostaviti več smeri nadaljnjega raziskovanja. Najpomembnejši je razvoj individualizirane in dinamične kulturne prilagodljivosti. Trenutno je večina sistemov prilagojenih skupini oz. trenutnemu kontekstu, medtem ko je uporaba dolgoročnih uporabniških preferenc redka.

Druga pomembna smer je razvoj formalnejšega kulturnega stanja, ki bi omogočalo eksplicitno predstavitev posameznih kulturnih parametrov, njihovega izvora in stopnje zaupanja.

Tretja je standardizacija vrednotenja. Področje potrebuje jasnejšo ločitev med tehnično pravilnostjo, uporabnostjo in dejanskim kulturnim prileganjem.

Četrta smer je razvoj kakovostnih in ponovno uporabnih kulturnih virov znanja, ki bi bili:

- sledljivi,
- raznoliki,
- posodobljivi,
- preverjeni v sodelovanju z uporabniki in
- zasnovani tako, da ne predstavljajo kulture kot fiksnega nabora pravil.

Pomembni bodo tudi ablacijski eksperimenti, ki bodo pokazali, ali kulturno prilagajanje dejansko izboljša sistem in kateri mehanizem je za izboljšanje odgovoren.

6.10 Omejitve izvedenega pregleda

Tudi izvedeni pregled ima več omejitev, ki jih je treba upoštevati pri interpretaciji rezultatov.

Prva je časovna omejitev na obdobje 2021–2026. Čeprav je bila izbrana zaradi osredotočenosti na sodobne pogovorne sisteme, so bila s tem izločena starejša dela o kulturnem prilagajanju klasičnih pogovornih agentov.

Druga omejitev je vključevanje samo publikacij v angleškem jeziku. To je pri raziskovanju kulture posebej pomembna omejitev, saj so lahko relevantne lokalne raziskave objavljene v drugih jezikih.

Tretja je prag najmanj dveh citatov, uporabljen kot praktični iskalni filter. Takšen kriterij lahko predvsem pri delih iz let 2025 in 2026 izloči kakovostne nove raziskave, ki še niso imele dovolj časa za pridobitev citatov. Ta omejitev je navedena tudi v raziskovalnem protokolu.

Četrta omejitev je velika heterogenost vključenih raziskav. V istem pregledu so empirični uporabniški poskusi, tehnične raziskave, podatkovni prispevki, pregledi in konceptualna dela. Zato kvantitativne pogostosti kažejo predvsem, kaj se v literaturi pojavlja, ne pa, kateri pristop ima največji učinek.

Peta omejitev je neenotno poročanje. Pri delu raziskav ni bilo mogoče zanesljivo določiti konkretnega modela, načina implementacije, velikosti vzorca ali dostopnosti podatkov in kode. V takšnih primerih podatki niso bili predpostavljeni, ampak so ostali označeni kot nejasni oz. neporočani.

Šesta omejitev je, da zaradi heterogenosti raziskav ni bila izvedena meta-analiza. Zato predlagana arhitektura ne predstavlja statistično dokazanega optimalnega pristopa, temveč sintezo ponavljajočih se arhitekturnih in metodoloških vzorcev v pregledani literaturi.

Sedma omejitev je, da je presejanje zapisov, pregled celotnih besedil ter končne odločitve o vključitvi izvedel en raziskovalec. Čeprav so bili dvoumni primeri ponovno pregledani s časovnim zamikom in je bila v posameznih primerih uporabljena dodatna pomoč pri interpretaciji, ni bilo mogoče izračunati medocenjevalske zanesljivosti. Zato ni mogoče izključiti vpliva subjektivne presoje pri posameznih odločitvah.

Osma omejitev se nanaša na dodatno kategorizacijo kulturnega in domenskega prostora znanja. Te kategorije predstavljajo analitično sintezo, oblikovano na podlagi ponavljajočih se vzorcev v pregledanih raziskavah, in niso standardizirana taksonomija, ki bi jo uporabljala vsa vključena dela. Posamezne razvrstitve so zato odvisne tudi od uporabljene interpretativne sheme.

Deveta omejitev je, da predlagana arhitektura v okviru tega dela še ni bila implementirana in eksperimentalno ovrednotena. Predstavlja konceptualno sintezo ugotovitev pregleda, zato bo treba njeno dejansko učinkovitost, vpliv posameznih komponent in sposobnost zmanjševanja stereotipizacije preveriti v nadaljnjem eksperimentalnem delu.

7 Zaključek

Razvoj LLM-jev je bistveno razširil možnosti uporabe pogovornih sistemov, hkrati pa odprl vprašanje njihove primernosti za kulturno raznolike uporabnike. Sodobni klepetalniki lahko ustvarjajo jezikovno tekoče in vsebinsko kompleksne odgovore, vendar to samo po sebi še ne zagotavlja, da so ti odgovori kulturno ustrezni. Kulturna prilagodljivost zato predstavlja pomemben raziskovalni problem, ki presega samo izbiro osnovnega jezikovnega modela in vključuje tudi način predstavitve kulturnega konteksta, pridobivanje znanja, personalizacijo, oblikovanje interakcije in vrednotenje končnega odziva.

Namen tega individualnega raziskovalnega dela je bil pregledati in sistematično kartirati obstoječe raziskave na področju kulturno prilagodljivih klepetalnikov in pogovornih sistemov AI. Pregled je bil izveden kot pregled obsega literature, pri čemer so bile raziskave identificirane v podatkovnih bazah Scopus, Web of Science Core Collection, IEEE Xplore in PubMed. Po deduplikaciji, pregledu naslovov in povzetkov ter oceni celotnih besedil je bilo v končno ekstrakcijo vključenih 51 raziskav. Od teh jih je bilo 42 ocenjenih kot neposredno povezanih z raziskovalno temo, 9 pa kot širše relevantnih za posamezne vidike zastavljenih raziskovalnih vprašanj.

Rezultati kažejo, da v literaturi ne obstaja enotna opredelitev kulturne prilagodljivosti. Kultura je najpogosteje operacionalizirana prek posameznih značilnosti oz. kulturnih signalov, kot so ciljna skupina, jezik in register, interakcijske norme, način komunikacije, občutljivost posameznih tem, zaupanje ter širši sociokulturni kontekst. Kulturni prostor znanja je bil v večini raziskav predstavljen implicitno ali le delno formalizirano, kar kaže, da področje še nima splošno sprejetega računalniškega modela kulture. Med najpogostejšimi skupinami kulturnih parametrov so bile identiteta ciljne skupnosti, interakcijske norme in slog, vprašanja občutljivosti in zaupanja ter jezik oz. register.

Pomembna ugotovitev pregleda je, da kulturna prilagodljivost večinoma ni implementirana neposredno v jedru LLM-ja. Pogosteje se pojavlja na ravni aplikacijske logike, vsebine, persone in načina interakcije ali kot dodatna zunanja plast okoli osnovnega modela. Med pregledanimi pristopi so bili uporabljeni pozivno prilagajanje, RAG, namenski kulturni in domenski viri znanja, participativno načrtovanje ter v manjšem obsegu fino nastavljanje modelov. To kaže, da je kulturno prilagodljivost primerneje obravnavati kot lastnost celotnega pogovornega sistema in ne samo osnovnega LLM-ja. Pregled ni pokazal enega osnovnega modela ali tehničnega pristopa, ki bi ga bilo mogoče na podlagi obstoječih rezultatov označiti kot splošno najboljšega za kulturno prilagodljivost.

Rezultati so pokazali tudi pomembno razliko med kulturnim in domenskim znanjem. Domensko znanje je v pregledanih sistemih praviloma bolj eksplicitno in vsebuje strokovno oz. nalogovno vsebino, medtem ko kulturni prostor določa predvsem način, kako naj bo ta vsebina predstavljena določeni skupini ali posamezniku. To razlikovanje omogoča, da se dejanska pravilnost odgovora loči od njegove kulturne ustreznosti. Za

razvoj prihodnjega sistema je zato smiselno ohraniti ločena, vendar povezana kulturni in domenski prostor znanja.

Podobna heterogenost je bila ugotovljena pri vrednotenju. Raziskave uporabljajo tehnične metrike, ocene uporabnosti, vključenosti, sprejemljivosti, zaupanja, klinične oz. psihološke izide in neposredne ocene kulturne občutljivosti oz. ustreznosti. Neposredne ocene kulturne občutljivosti ali primernosti so bile ugotovljene v 21 raziskavah, kar kaže, da velik del literature kulturno uspešnost sistema še vedno ocenjuje tudi s posrednimi kazalniki. Zato je pri prihodnjem vrednotenju pomembno ločevati med tehnično pravilnostjo, splošno uporabniško izkušnjo in dejanskim kulturnim prileganjem.

Posebej pomembna raziskovalna vrzel je omejena stopnja individualne in longitudinalne prilagodljivosti. Veliko obstoječih rešitev je kulturno prilagojenih določeni državi, jeziku ali skupini že med razvojem oz. kulturni kontekst določijo ob posamezni poizvedbi. Takšni sistemi so lahko kulturno primerni za ciljno skupino, vendar to še ne pomeni, da se dejansko prilagajajo posameznemu uporabniku skozi čas. Zato je smiselno razlikovati med kulturno prilagojenim in kulturno prilagodljivim sistemom.

Na podlagi sinteze rezultatov je bila v tem delu predlagana hibridna modularna arhitektura kulturno prilagodljivega klepetalnika. Osnovo predstavlja večjezični LLM, prilagojen sledenju navodilom, ki je povezan z ločenima domenskim in kulturnim prostorom znanja. RAG omogoča pridobivanje relevantnega strokovnega in kulturnega konteksta, pozivna plast usmerja način uporabe pridobljenih informacij, kulturno stanje predstavlja trenutno znane uporabnikove preference in kontekst, krmilnik prilagajanja pa določa, kateri kulturni parametri so za posamezno interakcijo relevantni. Po generiranju je predvideno dodatno preverjanje kulturne ustreznosti, varnosti in utemeljenosti odgovora. Rezultati ekstrakcije podpirajo smiselnost predlagane modularne zasnove z ločenima kulturnim in domenskim prostorom ter kombinacijo RAG, pozivne prilagoditve in kulturnega stanja uporabnika.

Ključno načelo predlagane arhitekture je, da skupinska oz. kulturna informacija ne predstavlja dokončnega opisa posameznika. Podatki, kot so jezik, država ali pripadnost določeni skupnosti, lahko služijo kot začetni kontekst, vendar morajo imeti neposredno izražene uporabnikove preference prednost pred takšnimi privzetimi vrednostmi. Sistem mora poleg tega omogočati izražanje negotovosti ter preprečevati, da bi kulturna personalizacija postala avtomatsko stereotipiziranje uporabnika. Pregled tako kaže, da je razvoj kulturno prilagodljivega pogovornega sistema predvsem problem povezovanja znanja, uporabniškega konteksta, generativnega modela in mehanizmov nadzora.

Naslednji korak je zato implementacija predlagane modularne arhitekture in njeno eksperimentalno vrednotenje, s katerim bo mogoče preveriti, ali dinamično kulturno stanje, ločena procesa kulturnega in domenskega RAG-a ter nadzor prilagajanja dejansko izboljšajo kulturno ustreznost odgovorov brez zmanjšanja njihove strokovne pravilnosti in varnosti.

Viri in literatura

- [1] A. Vaswani *idr.*, »Attention is All you Need«, v *Advances in Neural Information Processing Systems*, I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, in R. Garnett, Ur., Curran Associates, Inc., 2017. [Na spletu]. Dostopno na: https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fb053c1c4a845aa-Paper.pdf
- [2] R. Bommasani *idr.*, »On the Opportunities and Risks of Foundation Models«, 12. julij 2022, *arXiv*: arXiv:2108.07258. doi: 10.48550/arXiv.2108.07258.
- [3] J. Gao, M. Galley, in L. Li, »Neural Approaches to Conversational AI«, v *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics: Tutorial Abstracts*, Y. Artzi in J. Eisenstein, Ur., Melbourne, Australia: Association for Computational Linguistics, jul. 2018, str. 2–7. doi: 10.18653/v1/P18-5002.
- [4] J. W. Berry, »Immigration, Acculturation, and Adaptation«, *Applied Psychology*, let. 46, št. 1, str. 5–34, jan. 1997, doi: 10.1111/j.1464-0597.1997.tb01087.x.
- [5] D. K. Deardorff, »Identification and Assessment of Intercultural Competence as a Student Outcome of Internationalization«, *Journal of Studies in International Education*, let. 10, št. 3, str. 241–266, sep. 2006, doi: 10.1177/1028315306287002.
- [6] S. Ang *idr.*, »Cultural Intelligence: Its Measurement and Effects on Cultural Judgment and Decision Making, Cultural Adaptation and Task Performance«, *Manag. Organ. Rev.*, let. 3, št. 3, str. 335–371, nov. 2007, doi: 10.1111/j.1740-8784.2007.00082.x.
- [7] M. F. Adilazuarda *idr.*, »Towards Measuring and Modeling “Culture” in LLMs: A Survey«, v *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, Y. Al-Onaizan, M. Bansal, in Y.-N. Chen, Ur., Miami, Florida, USA: Association for Computational Linguistics, nov. 2024, str. 15763–15784. doi: 10.18653/v1/2024.emnlp-main.882.
- [8] Y. Tao, O. Viberg, R. S. Baker, in R. F. Kizilcec, »Cultural bias and cultural alignment of large language models«, *PNAS Nexus*, let. 3, št. 9, str. pgae346, sep. 2024, doi: 10.1093/pnasnexus/pgae346.
- [9] A. Rao, A. Yerukola, V. Shah, K. Reinecke, in M. Sap, »NormAd: A Framework for Measuring the Cultural Adaptability of Large Language Models«, v *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, L. Chiruzzo, A. Ritter, in L. Wang, Ur., Albuquerque, New Mexico: Association for Computational Linguistics, apr. 2025, str. 2373–2403. doi: 10.18653/v1/2025.naacl-long.120.
- [10] P. Lewis *idr.*, »Retrieval-augmented generation for knowledge-intensive NLP tasks«, v *Proceedings of the 34th International Conference on Neural Information Processing Systems*, v NIPS '20. Red Hook, NY, USA: Curran Associates Inc., 2020.
- [11] P. Liu, W. Yuan, J. Fu, Z. Jiang, H. Hayashi, in G. Neubig, »Pre-train, Prompt, and Predict: A Systematic Survey of Prompting Methods in Natural Language Processing«, *ACM Comput. Surv.*, let. 55, št. 9, jan. 2023, doi: 10.1145/3560815.
- [12] E. J. Hu *idr.*, »LoRA: Low-Rank Adaptation of Large Language Models«, *ArXiv*, let. abs/2106.09685, 2021, [Na spletu]. Dostopno na: <https://api.semanticscholar.org/CorpusID:235458009>

- [13] H. Arksey in L. O'Malley, »Scoping studies: towards a methodological framework«, *International Journal of Social Research Methodology*, let. 8, št. 1, str. 19–32, feb. 2005, doi: 10.1080/1364557032000119616.
- [14] A. C. Tricco *idr.*, »PRISMA Extension for Scoping Reviews (PRISMA-ScR): Checklist and Explanation«, *Ann Intern Med*, let. 169, št. 7, str. 467–473, okt. 2018, doi: 10.7326/M18-0850.
- [15] G. Hofstede, »Culture's Recent Consequences: Using Dimension Scores in Theory and Research«, *Int'l Jnl of Cross Cultural Management*, let. 1, št. 1, str. 11–17, apr. 2001, doi: 10.1177/147059580111002.
- [16] P. Brewer in S. Venaik, »The Ecological Fallacy in National Culture Research«, *Organization Studies*, let. 35, št. 7, str. 1063–1086, jul. 2014, doi: 10.1177/0170840613517602.
- [17] S. H. Schwartz, »Universals in the Content and Structure of Values: Theoretical Advances and Empirical Tests in 20 Countries«, let. 25, M. P. Zanna, Ur., v *Advances in Experimental Social Psychology*, vol. 25. , Academic Press, 1992, str. 1–65. doi: [https://doi.org/10.1016/S0065-2601\(08\)60281-6](https://doi.org/10.1016/S0065-2601(08)60281-6).
- [18] S. Schwartz, »A Theory of Cultural Value Orientations: Explication and Applications«, *Comp Sociol*, let. 5, št. 2–3, str. 137–182, 2006, doi: 10.1163/156913306778667357.
- [19] Y. Wang *idr.*, »CDEval: A Benchmark for Measuring the Cultural Dimensions of Large Language Models«, v *Proceedings of the 2nd Workshop on Cross-Cultural Considerations in NLP*, V. Prabhakaran, S. Dev, L. Benotti, D. Herscovich, L. Cabello, Y. Cao, I. Adebara, in L. Zhou, Ur., Bangkok, Thailand: Association for Computational Linguistics, avg. 2024, str. 1–16. doi: 10.18653/v1/2024.c3nlp-1.1.
- [20] C. Li, M. Chen, J. Wang, S. Sitaram, in X. Xie, »CultureLLM: Incorporating Cultural Differences into Large Language Models«, v *NeurIPS 2024*, feb. 2024. [Na spletu]. Dostopno na: <https://www.microsoft.com/en-us/research/publication/culturellm-incorporating-cultural-differences-into-large-language-models/>
- [21] T. B. Brown *idr.*, »Language models are few-shot learners«, v *Proceedings of the 34th International Conference on Neural Information Processing Systems*, v NIPS '20. Red Hook, NY, USA: Curran Associates Inc., 2020.
- [22] L. Ouyang *idr.*, »Training language models to follow instructions with human feedback«, v *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, in A. Oh, Ur., Curran Associates, Inc., 2022, str. 27730–27744. doi: 10.52202/068431-2011.
- [23] W. X. Zhao *idr.*, »A Survey of Large Language Models«, *Front. Comput. Sci.*, let. 20, št. 12, str. 2012627, dec. 2026, doi: 10.1007/s11704-026-60308-3.
- [24] S. Es, J. James, L. Espinosa Anke, in S. Schockaert, »RAGAs: Automated Evaluation of Retrieval Augmented Generation«, v *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, St. Julians, Malta: Association for Computational Linguistics, 2024, str. 150–158. doi: 10.18653/v1/2024.eacl-demo.16.
- [25] D. Levac, H. Colquhoun, in K. K. O'Brien, »Scoping studies: advancing the methodology«, *Implementation Sci*, let. 5, št. 1, str. 69, dec. 2010, doi: 10.1186/1748-5908-5-69.

- [26] M. D. Peters, C. Godfrey, P. McInerney, Z. Munn, A. C. Tricco, in H. Khalil, »Scoping reviews«, v *JBIM Manual for Evidence Synthesis*, E. Aromataris, C. Lockwood, K. Porritt, B. Pilla, in Z. Jordan, Ur., JBI, 2024. doi: 10.46658/JBIMES-24-09.
- [27] K. Seaborn, Y. Sawa, in M. Watanabe, »Coimagining the Future of Voice Assistants with Cultural Sensitivity«, *Human Behavior and Emerging Technologies*, let. 2024, str. 1–21, mar. 2024, doi: 10.1155/2024/3238737.
- [28] Z. Qian, J. Fu, in Y. Zhou, »Exploring Cultural and Intergenerational Dynamics in Voice Assistant Design for Chinese Older Adults«, *Proc. ACM Interact. Mob. Wearable Ubiquitous Technol.*, let. 9, št. 1, str. 1–18, mar. 2025, doi: 10.1145/3712275.
- [29] P. K. Adhikary *idr.*, »Menstrual Health Education Using a Specialized Large Language Model in India: Development and Evaluation Study of MenstLLaMA«, *J Med Internet Res*, let. 27, str. e71977–e71977, jul. 2025, doi: 10.2196/71977.
- [30] A. Jain, A. Tiwari, P. Kumar, K. Londhe, S. Kumar, in A. Chaturvedi, »Saarthi: Ensemble AI4Bharat IndicTrans2 and Gemini for Multilingual Indian Chatbot«, v *2025 5th International Conference on AI-ML-Systems (AIMLSystems)*, Bangalore, India: IEEE, okt. 2025, str. 207–210. doi: 10.1109/AIMLSystems67835.2025.11330894.
- [31] C.-C. Chang, H.-P. Chang, in H.-S. Lee, »Leveraging Retrieval-Augmented Generation for Culturally Inclusive Hakka Chatbots: Design Insights and User Perceptions«, v *2024 IEEE International Conference on Recent Advances in Systems Science and Engineering (RASSE)*, Taichung, Taiwan: IEEE, nov. 2024, str. 1–6. doi: 10.1109/RASSE64357.2024.10773731.
- [32] M. Tuna, K. Schaaff, in T. Schlippe, »Effects of Language- and Culture-Specific Prompting on ChatGPT«, v *2024 2nd International Conference on Foundation and Large Language Models (FLLM)*, Dubai, United Arab Emirates: IEEE, nov. 2024, str. 73–81. doi: 10.1109/FLLM63129.2024.10852463.
- [33] X. Zhao, Y. Sun, W. Liu, in C.-W. Wong, »Tailoring generative AI chatbots for multiethnic communities in disaster preparedness communication: extending the CASA paradigm«, *Journal of Computer-Mediated Communication*, let. 30, št. 1, str. zmae022, jan. 2025, doi: 10.1093/jcmc/zmae022.
- [34] T.-P. Nguyen, S. Razniewski, in G. Weikum, »Cultural Commonsense Knowledge for Intercultural Dialogues«, v *Proceedings of the 33rd ACM International Conference on Information and Knowledge Management*, Boise ID USA: ACM, okt. 2024, str. 1774–1784. doi: 10.1145/3627673.3679768.
- [35] S. Hu *idr.*, »MULTI 3 WOZ : A Multilingual, Multi-Domain, Multi-Parallel Dataset for Training and Evaluating Culturally Adapted Task-Oriented Dialog Systems«, *Transactions of the Association for Computational Linguistics*, let. 11, str. 1396–1415, nov. 2023, doi: 10.1162/tacl_a_00609.
- [36] Y. Wang, X. Li, Q. Zhang, D. Yeung, in Y. Wu, »Effect of a Cognitive Behavioral Therapy-Based AI Chatbot on Depression and Loneliness in Chinese University Students: Randomized Controlled Trial With Financial Stress Moderation«, *JMIR Mhealth Uhealth*, let. 13, str. e63806–e63806, avg. 2025, doi: 10.2196/63806.
- [37] O. Miles, S. Pinckard, M. Gungor, D. Ridge, in T. Nadarzynski, »Exploring acceptability of AI-enabled voice assistants and digital AI humans in healthcare: a

cross-sectional survey», *AI & Soc*, let. 40, št. 8, str. 6783–6797, dec. 2025, doi: 10.1007/s00146-025-02332-8.

- [38] W. Liu, Y. Huang, in X. Zhao, »Exploring the contingent effect of cultural tailoring of GenAI chatbots on multiethnic members' disaster information seeking and preparation attitude: A cross-group comparison«, *International Journal of Disaster Risk Reduction*, let. 126, str. 105639, avg. 2025, doi: 10.1016/j.ijdr.2025.105639.
- [39] A. Babington-Ashaye, P. De Moerloose, S. Diop, in A. Geissbuhler, »Design, development and usability of an educational AI chatbot for People with Haemophilia in Senegal«, *Haemophilia*, let. 29, št. 4, str. 1063–1073, jul. 2023, doi: 10.1111/hae.14815.
- [40] S. Lee, D. Choi, L. Truong, N. Sawhney, in H. Paakki, »Into the Unknown: Leveraging Conversational AI in Supporting Young Migrants' Journeys Towards Cultural Adaptation«, v *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*, Yokohama Japan: ACM, apr. 2025, str. 1–19. doi: 10.1145/3706598.3713091.

Priloge

Priloga A Iskalni nizi posameznih repozitorijev

Scopus

```
TITLE-ABS-KEY((chatbot* OR "conversational agent*" OR "dialogue system*" OR "dialog system*" OR "conversational AI" OR "virtual assistant*" OR "voice assistant*" OR "AI assistant*") AND ((cultur* W/3 adapt*) OR (cultur* W/3 aware*) OR (cultur* W/3 sensitiv*) OR (cultur* W/3 responsiv*) OR (cultur* W/3 align*) OR (cultur* W/3 appropriate*)))
```

Web of Science Core Collection

```
TS=((chatbot* OR "conversational agent*" OR "dialogue system*" OR "dialog system*" OR "conversational AI" OR "virtual assistant*" OR "voice assistant*" OR "AI assistant*") AND ((cultur* NEAR/3 adapt*) OR (cultur* NEAR/3 aware*) OR (cultur* NEAR/3 sensitiv*) OR (cultur* NEAR/3 responsiv*) OR (cultur* NEAR/3 align*) OR (cultur* NEAR/3 appropriate*)))
```

IEEE Xplore

```
(chatbot* OR "conversational agent*" OR "dialogue system*" OR "dialog system*" OR "conversational AI" OR "virtual assistant*" OR "voice assistant*" OR "AI assistant*") AND ("cultural adapt*" OR "culturally adaptive" OR "cultural awareness" OR "cultural sensitivity" OR "cultural responsiveness" OR "cultural alignment" OR "culturally appropriate")
```

PubMed

```
((chatbot*[tiab] OR "conversational agent"[tiab] OR "dialogue system"[tiab] OR "dialog system"[tiab] OR "conversational AI"[tiab] OR "virtual assistant"[tiab] OR "voice assistant"[tiab] OR "AI assistant"[tiab])) AND ((cultural adapt*[tiab] OR culturally adapt*[tiab] OR cultural aware*[tiab] OR culturally aware[tiab] OR cultural sensitiv*[tiab] OR culturally sensitiv*[tiab] OR cultural responsiv*[tiab] OR culturally responsiv*[tiab] OR cultural align*[tiab] OR culturally align*[tiab] OR cultural appropriate*[tiab] OR culturally appropriate*[tiab]))
```

Priloga B Seznam vključenih raziskav

Naslov dela	DOI
Effect of a Cognitive Behavioral Therapy-Based AI Chatbot on Depression and Loneliness in Chinese University Students: Randomized Controlled Trial With Financial Stress Moderation	10.2196/63806
Exploring the contingent effect of cultural tailoring of GenAI chatbots on multiethnic members' disaster information seeking and preparation attitude: A cross-group comparison	10.1016/j.ijdr.2025.105639
Into the Unknown: Leveraging Conversational AI in Supporting Young Migrants' Journeys Towards Cultural Adaptation	10.1145/3706598.3713091
Designing Delight: Exploring the Nexus of Interactive Design, User Experience, and Psychological Theory in Banking Chatbot	10.62441/nano-ntp.v20iS4.28

Toward cultural interpretability: A linguistic anthropological framework for describing and evaluating large language models	10.1177/20539517241303118
Exploring acceptability of AI-enabled voice assistants and digital AI humans in healthcare: a cross-sectional survey	10.1007/s00146-025-02332-8
Personalized Care in Eye Health: Exploring Opportunities, Challenges, and the Road Ahead for Chatbots	10.3390/jpm13121679
Design, development and usability of an educational AI chatbot for People with Haemophilia in Senegal	10.1111/hae.14815
Coimagining the Future of Voice Assistants with Cultural Sensitivity	10.1155/2024/3238737
Formative Evaluation of the Acceptance of HIV Prevention Artificial Intelligence Chatbots by Men Who Have Sex with Men in Malaysia: Focus Group Study	10.2196/42055
Enhancing Natural Language Processing in Multilingual Chatbots for Cross-Cultural Communication	10.1109/ICICV62344.2024.00027
Survey of Cultural Awareness in Language Models: Text and Beyond	10.1162/COLL.a.14
Emotion-Aware Chatbot with Cultural Adaptation for Mitigating Work-Related Stress	10.1145/3604571.3604578
Improving EFL students' cultural awareness: Reframing moral dilemmatic stories with ChatGPT	10.1016/j.caeai.2024.100223
Cultural Self-Adaptive Multimodal Gesture Generation Based on Multiple Culture Gesture Dataset	10.1145/3581783.3611705
Symmetric Therapeutic Frameworks and Ethical Dimensions in AI-Based Mental Health Chatbots (2020–2025): A Systematic Review of Design Patterns, Cultural Balance, and Structural Symmetry	10.3390/sym17071082
“Rosita Reads With My Family”: Developing A Bilingual Conversational Agent to Support Parent-Child Shared Reading	10.1145/3585088.3589354
Leveraging Retrieval-Augmented Generation for Culturally Inclusive Hakka Chatbots: Design Insights and User Perceptions	10.1109/RASSE64357.2024.10773731
Development and Evaluation of a Mental Health Chatbot Using ChatGPT 4.0: Mixed Methods User Experience Study With Korean Users	10.2196/63538

A WGAN-Based Dialogue System for Embedding Humor, Empathy, and Cultural Aspects in Education	10.1109/ACCESS.2023.3294966
Adapting Communication Styles in Health Chatbot using Large Language Models to Support Family Caregivers from Multicultural Backgrounds	10.1145/3706599.3719711
Menstrual Health Education Using a Specialized Large Language Model in India: Development and Evaluation Study of MenstLLaMA	10.2196/71977
Contextualized Visual Storytelling for Conversational Chatbot in Education	10.1145/3747327.3764895
Language adaptations of mental health interventions: User interaction comparisons with an AI-enabled conversational agent (Wysa) in English and Spanish	10.1177/20552076241255616
Effectiveness of embodied conversational agents for managing academic stress at an Indian University (ARU) during COVID-19	10.1111/bjet.13174
MULTI3WOZ: A Multilingual, Multi-Domain, Multi-Parallel Dataset for Training and Evaluating Culturally Adapted Task-Oriented Dialog Systems	10.1162/tacl_a_00609
A qualitative content analysis of ChatGPT's client simulation role-play for practising counselling skills	10.1002/capr.12699
Students' perceptions of AI mental health chatbots: an exploratory qualitative study at Sultan Qaboos University	10.1136/bmjopen-2025-103893
Formative evaluation of the acceptance of HIV prevention Artificial Intelligence chatbots by Black gay, bisexual, and other men who have sex with men in the Southern United States: Focus group study	10.1371/journal.pdig.0000891
Exploring Cultural and Intergenerational Dynamics in Voice Assistant Design for Chinese Older Adults	10.1145/3712275
Chatbot -assisted self-assessment (CASA): Co-designing an AI -powered behaviour change intervention for ethnic minorities	10.1371/journal.pdig.0000724
Inter(sectional) Alia(s): Ambiguity in Voice Agent Identity via Intersectional Japanese Self-Referents	10.1145/3706598.3713323

Exploring Socio-Cultural Challenges and Opportunities in Designing Mental Health Chatbots for Adolescents in India	10.1145/3706599.3720137
Attitudes Toward Use of an APOL1 Genetic Testing Chatbot in Living Kidney Donor Evaluation: A Focus Group Study	10.1111/ctr.70026
The development of a World Health Organization transdiagnostic chatbot intervention for distressed adolescents and young adults	10.3389/fdgth.2025.1528580
Cultural Commonsense Knowledge for Intercultural Dialogues	10.1145/3627673.3679768
Kya family planning after marriage hoti hai?: Integrating Cultural Sensitivity in an LLM Chatbot for Reproductive Health	10.1145/3706598.3713362
Usability and Acceptability of a Conversational Agent Health Education App (Nthabi) for Young Women in Lesotho: Quantitative Study	10.2196/52048
Adaptation of the Gabby conversational agent system to improve the sexual and reproductive health of young women in Lesotho	10.3389/fdgth.2023.1224429
Enthusiasts, Pragmatists, and Skeptics: Investigating Users' Attitudes Towards Emotion- and Personality-Aware Voice Assistants across Cultures	10.1145/3543758.3543776
Silver-Tongued and Sundry: Exploring Intersectional Pronouns with ChatGPT	10.1145/3613904.3642303
Tailoring generative AI chatbots for multiethnic communities in disaster preparedness communication: extending the CASA paradigm	10.1093/jcmc/zmae022
Designing for Harm Reduction: Communication Repair for Multicultural Users' Voice Interactions	10.1145/3613904.3642900
Development of a culturally targeted chatbot to inform living kidney donor candidates of African ancestry about APOL1 genetic testing: a mixed methods study	10.1007/s12687-024-00698-8
Improving body image at scale among Brazilian adolescents: study protocol for the co-creation and randomised trial evaluation of a chatbot intervention	10.1186/s12889-021-12129-1
Treatment Adherence in Chronic Conditions during Ageing: Uses, Functionalities, and Cultural Adaptation of the Assistant on Care and Health Offline (ACHO) in Rural Areas	10.3390/jpm11030173

Adapting a transdiagnostic digital mental health intervention for use among immigrant and refugee youth in Seattle: a human-centered design approach	10.1093/tbm/ibad041
Effects of Language- and Culture-Specific Prompting on ChatGPT	10.1109/FLLM63129.2024.10852463
Development of a Mental Health Chatbot Using Large Language Models for Indonesian Undergraduates	10.1109/IC3INA64086.2024.10732708
Educational Intelligent Chat Bot for Von Willebrand Disease Among Senegalese People	10.1109/ICSES63445.2024.10763201
Saarthi: Ensemble AI4Bharat IndicTrans2 and Gemini for Multilingual Indian Chatbot	10.1109/AIMLSystems67835.2025.11330894